Analyse exploratoire & feature engineering

Un parcours complet d'analyse du jeu Ames Housing, de l'exploration des données à l'optimisation des modèles de prédiction de prix immobiliers.

Contexte du projet

Jeu de données Ames Housing

Une base riche avec **79 variables** décrivant 1 460 maisons vendues à Ames, Iowa entre 2006 et 2010.

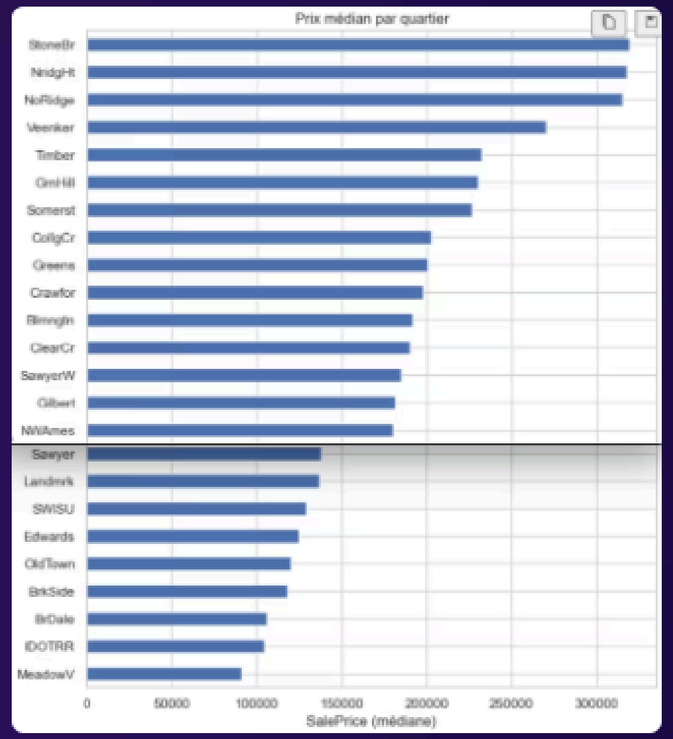

Distribution du prix de vente

Concentration

La majorité des ventes se concentrent entre **100 000$ et 200 000$**, visible sur l'histogramme et la KDE.

Asymétrie positive

Queue à droite marquée (*skew*) indiquant des valeurs élevées rares mais significatives.

Transformation log

Le **Q-Q plot** révèle une non-normalité. La transformation **log1p(SalePrice)** sera utilisée pour améliorer les modèles.

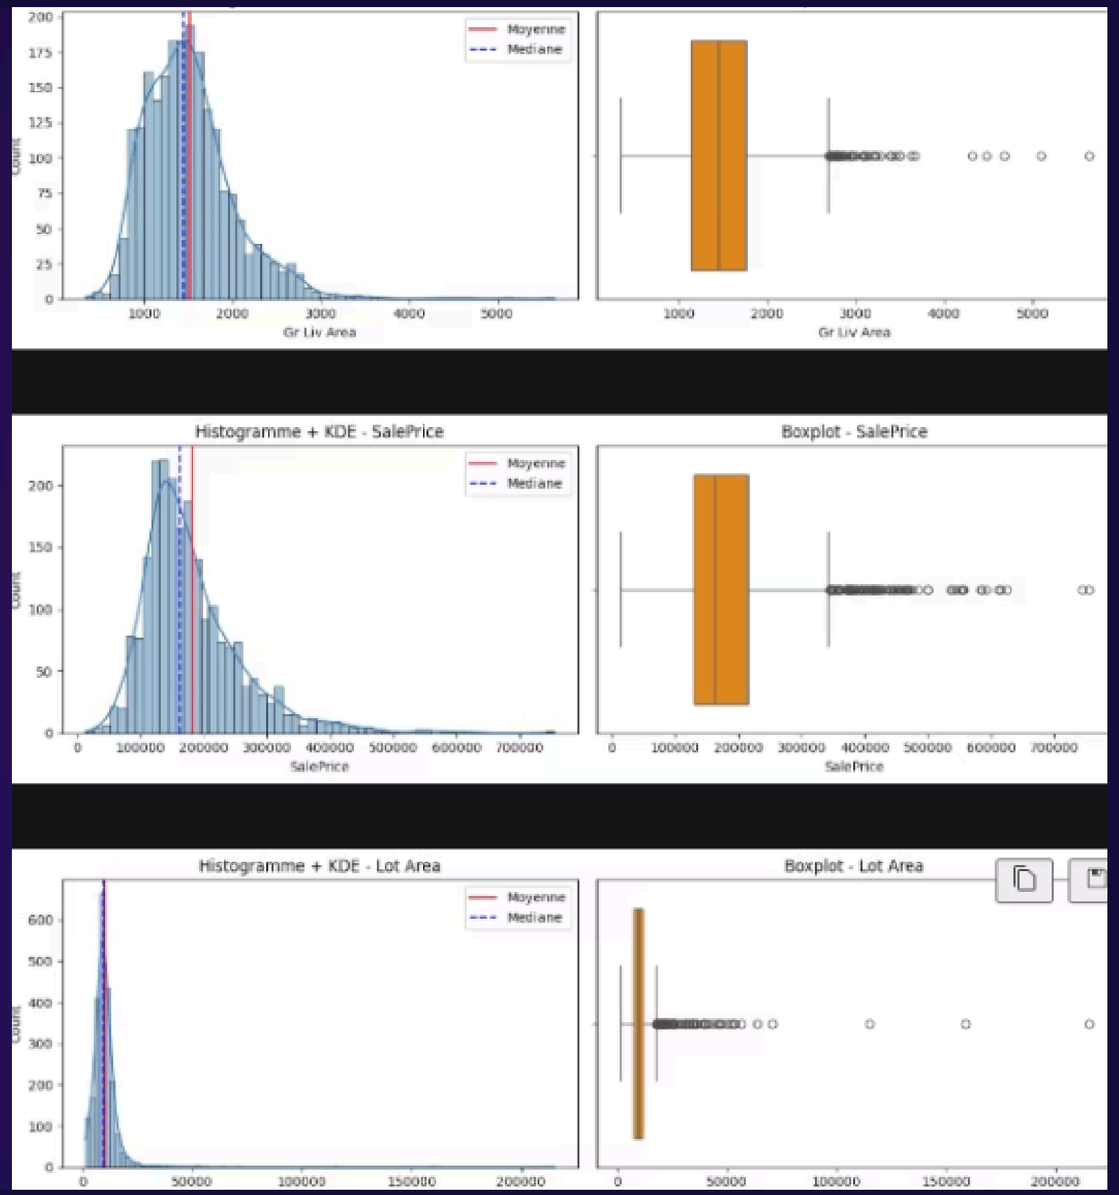

Prix et localisation par quartier

Écarts marqués

La variable **Neighborhood** révèle des écarts de niveau de prix significatifs selon la localisation.

Levier clé

La localisation est un facteur déterminant du prix. À compléter par des variables structurelles pour affiner l'analyse.

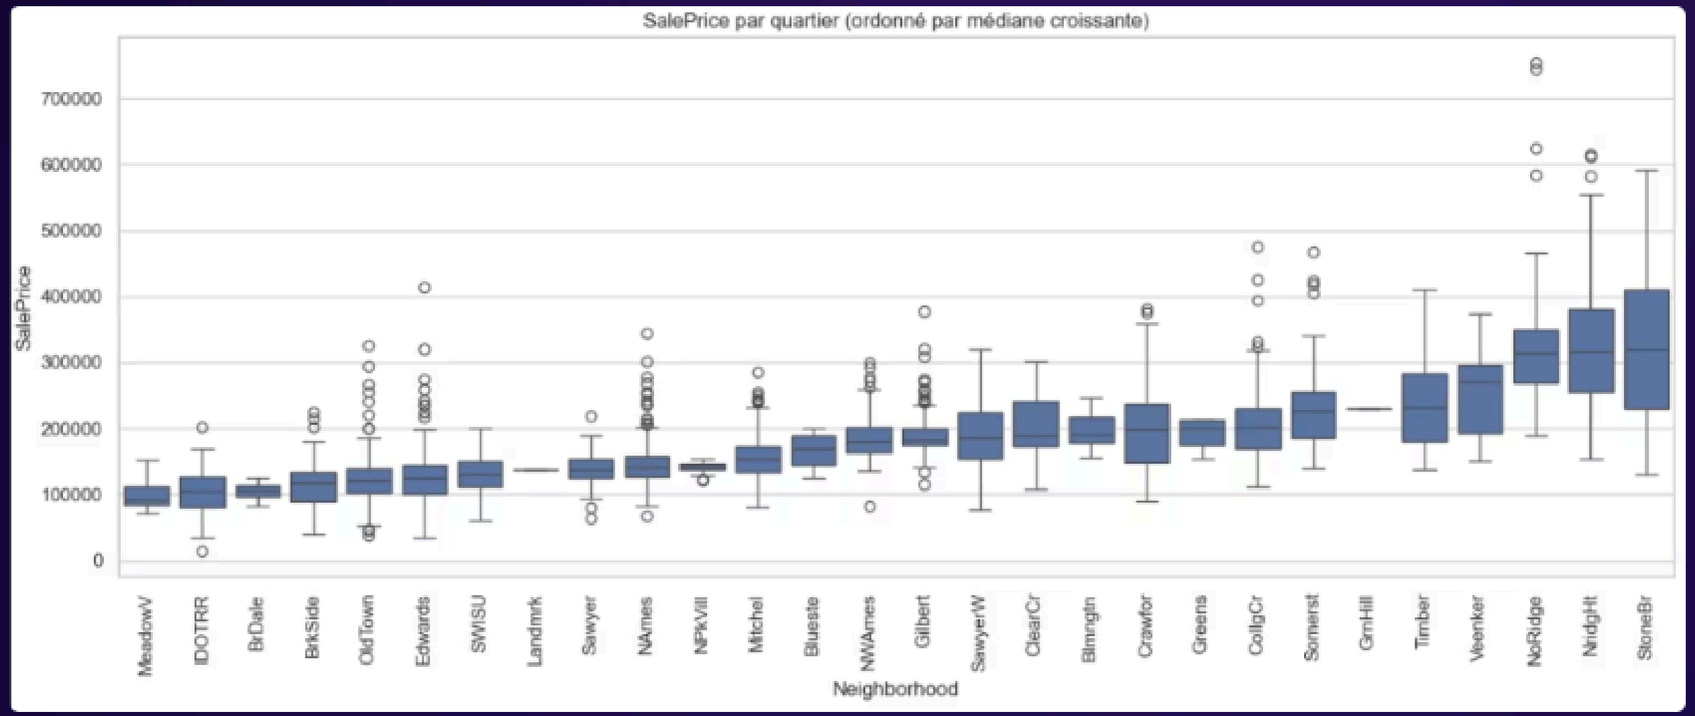

Analyse des tendances selon l'année de construction

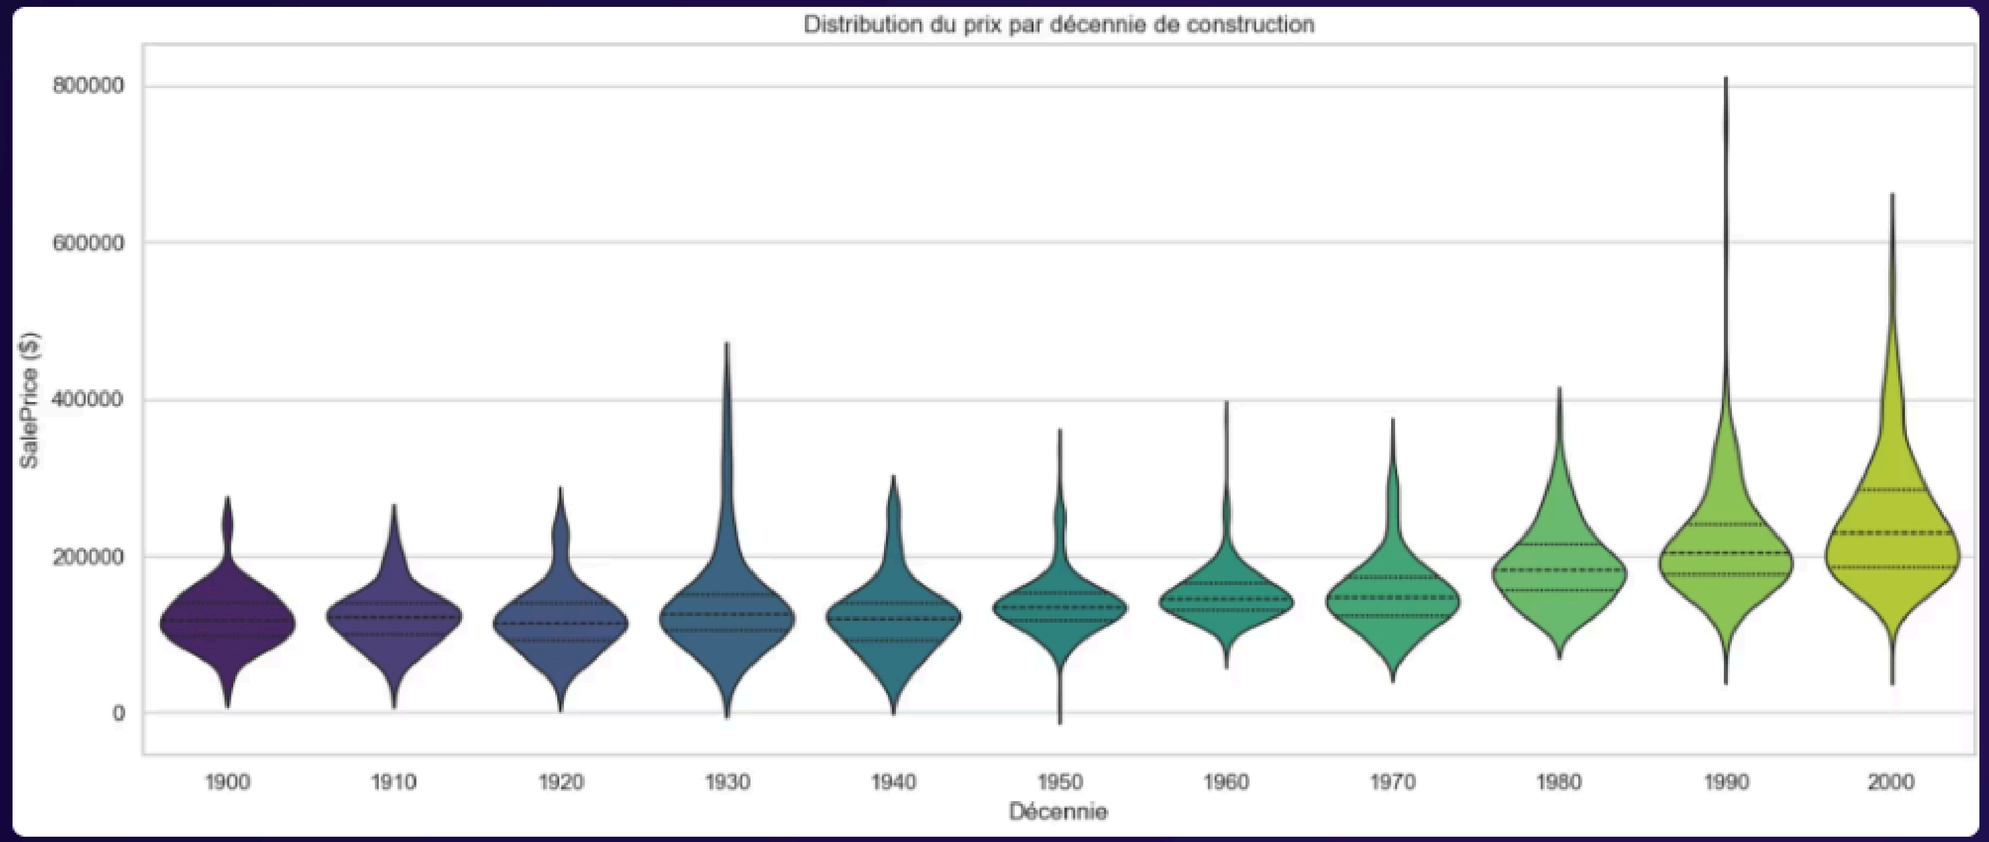

Notebook

Histogramme + KDE

Visualisation de la distribution avec concentration principale et queue à droite.

Boxplot

Identification des **outliers** hauts et mesure de la dispersion interquartile.

Variables catégorielles : effectifs

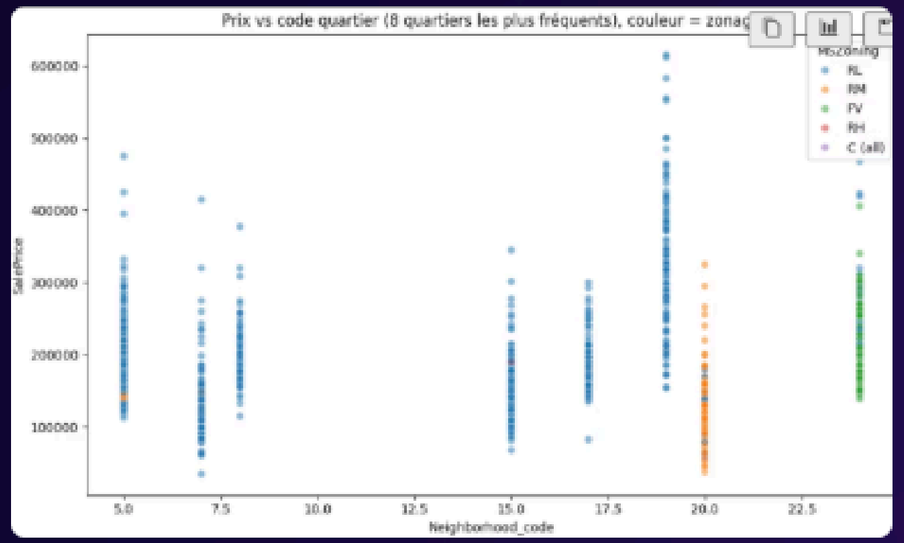

Neighborhood

Modalités **déséquilibrées** : NAmes, CollgCr et OldTown dominent.

MSZoning

RL (Residential Low density) représente la quasi-totalité.

Conditions

Condition1/2 : quasi tout **Norm** → faible variabilité. Condition2 quasi constante.

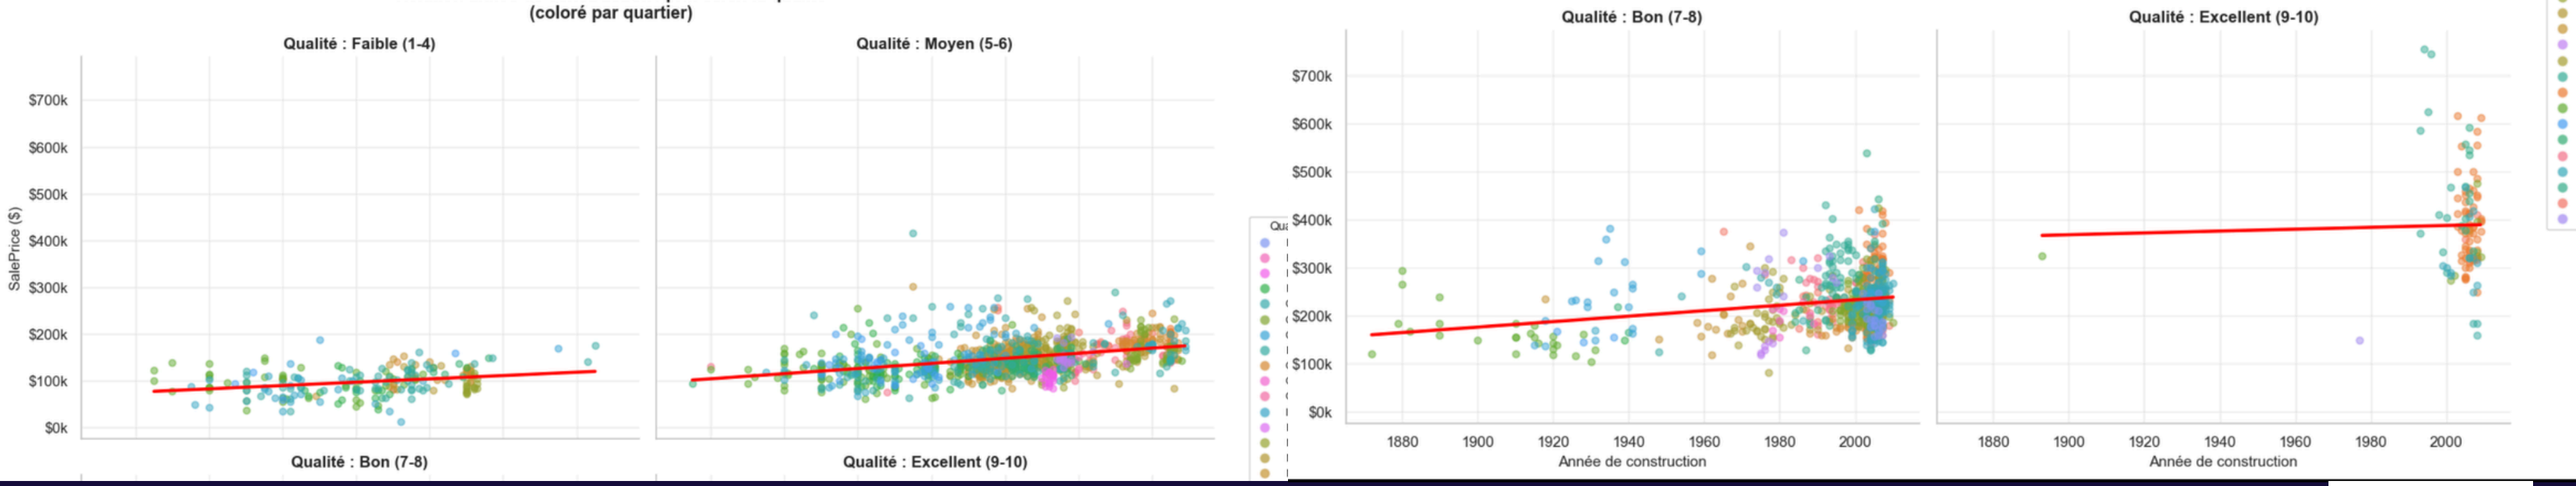

Heatmap Neighborhood × Qualité

Le prix médian augmente à la fois avec la qualité et selon le quartier. Certains quartiers amplifient l'effet de la qualité sur le prix.

Interaction triple clé entre année de construction, qualité et localisation :

01

Effet de la qualité :

Les biens « Excellent » (9-10) affichent une pente plus forte que les biens « Faible » (1-4)

02

Effet de la localisation :

Les couleurs montrent que les quartiers réagissent différemment.

Un bien récent et de très bonne qualité dans un quartier favorable cumule les avantages et atteint les prix les plus élevés (~$400-500k). À l'inverse, un bien ancien et de faible qualité, même dans un bon quartier, restera moins valorisé (~$100-150k). Cela confirme que **prix = qualité × localisation × ancienneté**, avec des **effets multiplicatifs**.

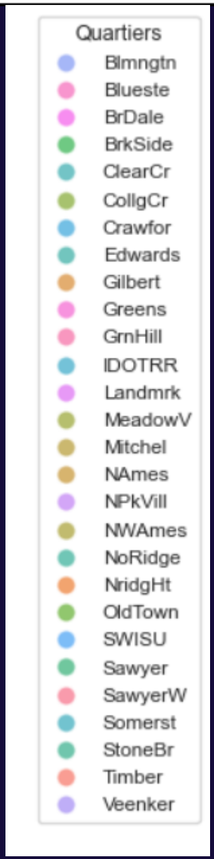

Amélioration des performances du modèle (RMSE)

53k

Localisation seule

35k

+ variables structurelles

33k

+ log + Ridge / FE

31.8k

+ features métier enrichies

Résultats

- E5bis (localisation seule) → **~53k**
- + variables structurelles (surface, qualité) → **~35k**
- + log + Ridge / FE → **~33k**
- + features métier enrichies → **~31.8k**

Insights clés

- Ajouter des variables réduit fortement l'erreur
- Les variables structurelles sont plus explicatives que la localisation seule
- La transformation **log1p(y)** améliore la stabilité du modèle
- Le feature engineering apporte un gain marginal mais décisif

Pistes d'amélioration & analyses avancées

Enrichissement des variables

- **Age** : ancienneté du bien et effets non linéaires
- **Interactions** : quartier, qualité, surface et garage
- Nettoyage : winsorization : garder l'interval de valeurs 5%-95%

Objectif : passer sous les **30k RMSE** et améliorer la compréhension du modèle

- **RMSE en baisse** grâce à des variables plus riches et des modèles plus performants
- **Meilleure interprétation**, plus robuste.
- **Modèle plus solide** face aux valeurs aberrantes et aux cas complexes
- Meilleur design

Merci de votre attention