ANALYSES MULTIVARIÉES ET CORRÉLATIONS

OBJECTIFS D'APPRENTISSAGE

- Identifier et quantifier les relations entre multiples variables
- Interpréter correctement les corrélations (limites, causalité, confounders)
- Détecter la multicolinéarité et les patterns complexes et le VIF
- Créer des visualisations multivariées lisibles (heatmaps, pair plots, parallel coordinates)

IDENTIFIER ET QUANTIFIER LES RELATIONS ENTRE MULTIPLES VARIABLES

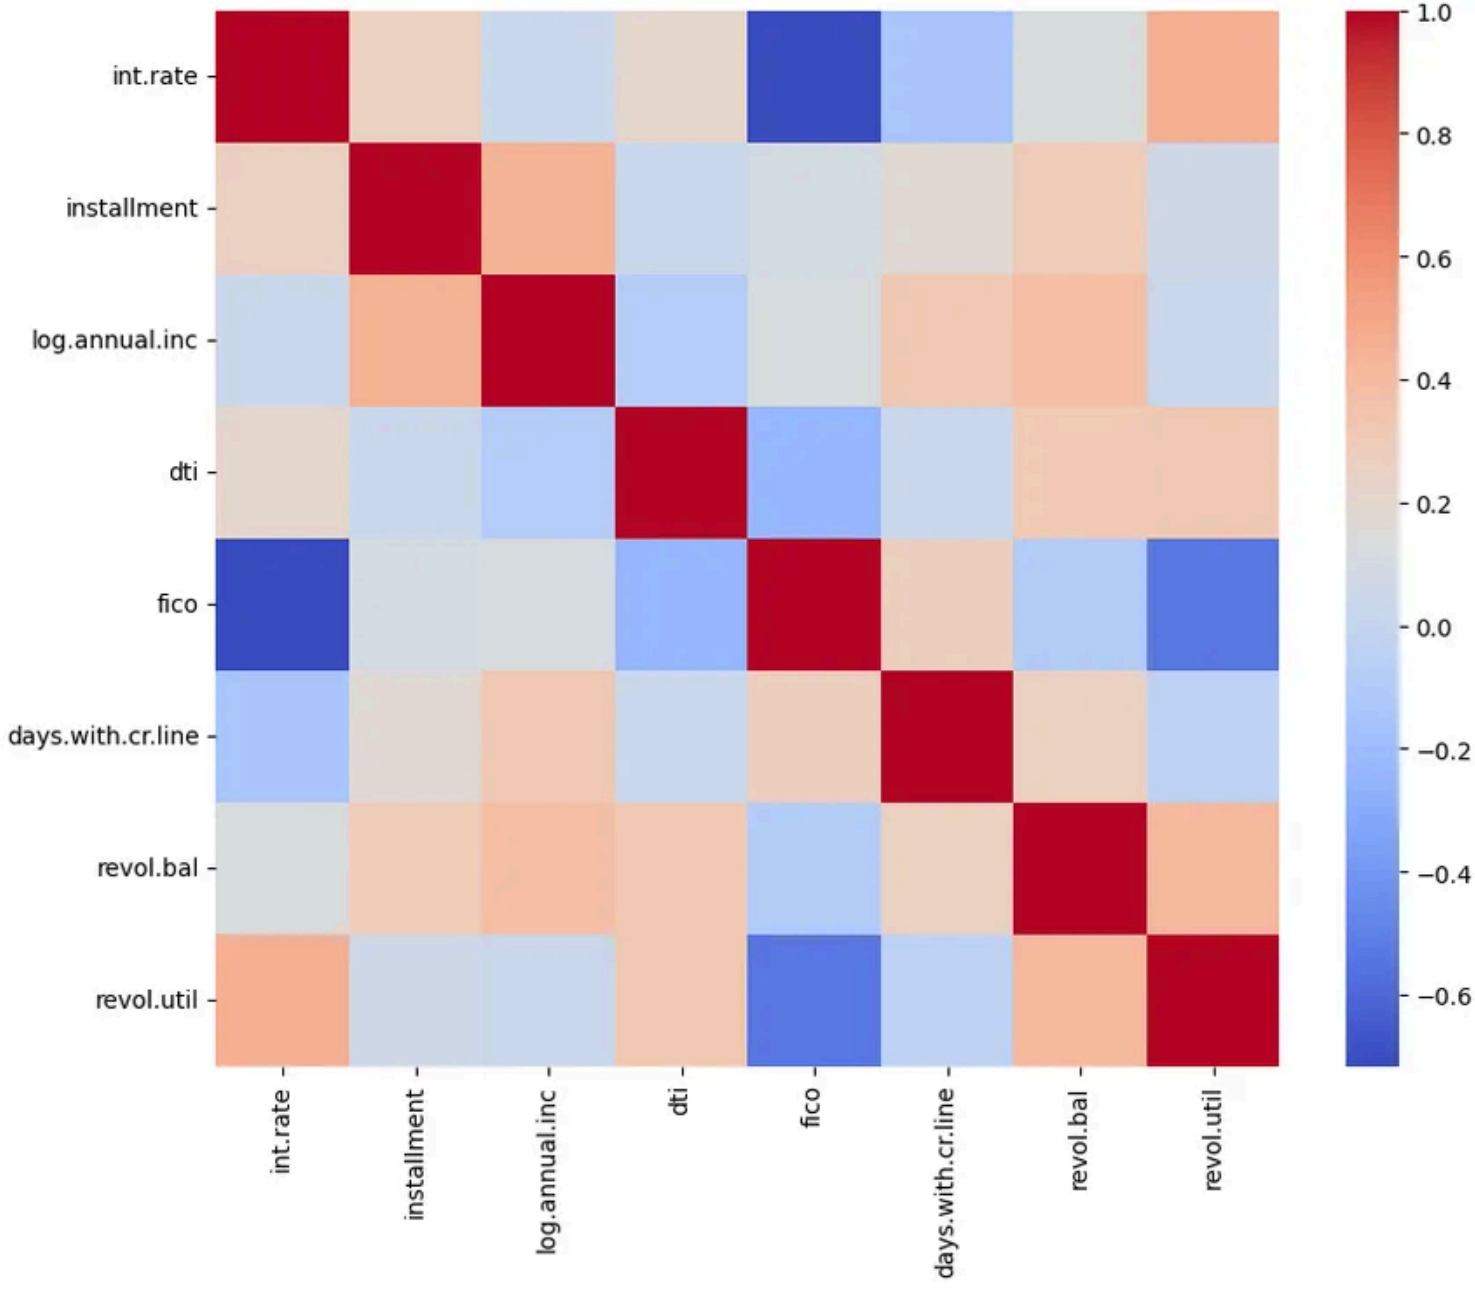
int.rate
installment
log.annual.inc
dti
fico
days.with.cr.line
revol.bal
revol.util
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4
−0.6

MESURES DE CORRÉLATION: PEARSON (R)

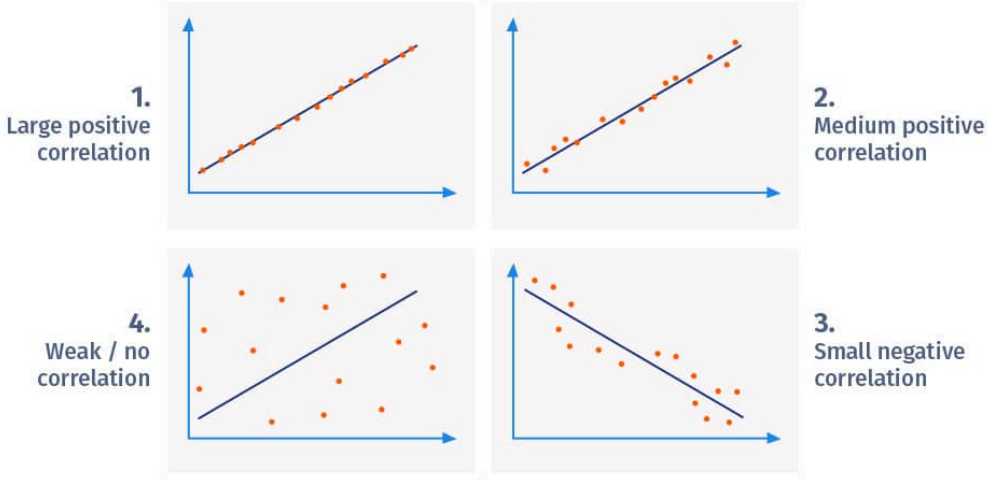

- **Pearson (r)** mesure les relations *linéaires* **entre deux variables quantitatives**. Sensible aux outliers
- r évolue entre -1 et +1

```
df.corr()
x.corr(y) -> np.float64(0.6996746308182467)
```

MESURES DE CORRÉLATION: SPEARMAN

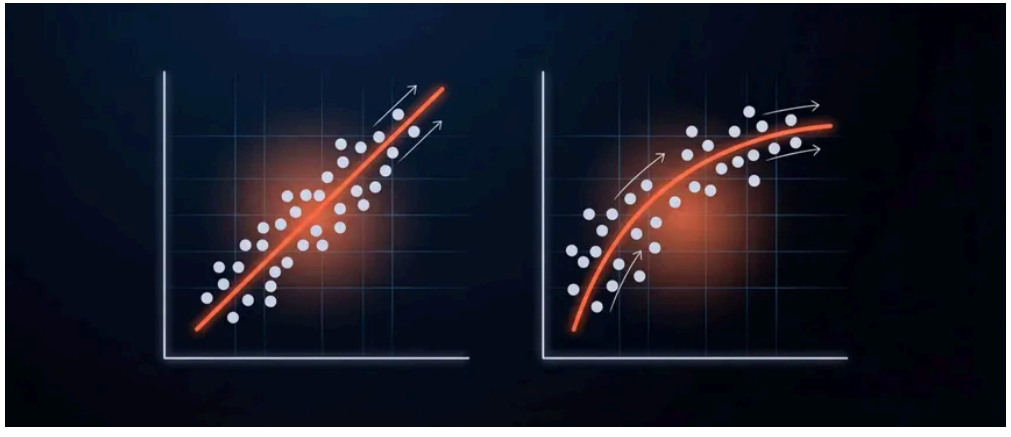

- **Objectif** : mesurer si deux variables évoluent dans la même direction, même si ce n'est pas en ligne droite.
- **Fonctionnement** : elle utilise les **rangs** (classement) plutôt que les valeurs brutes.
- **Interprétation** :
  - ρ (rho) = 1 → classement identique (relation monotone positive parfaite)
  - ρ = –1 → classement inverse (relation monotone négative parfaite)
  - ρ = 0 → pas de relation monotone
- **Avantages** : robuste aux outliers, adaptée aux relations non linéaires mais monotones.

MESURES DE CORRÉLATION: RELATIONS NON-LINÉAIRES

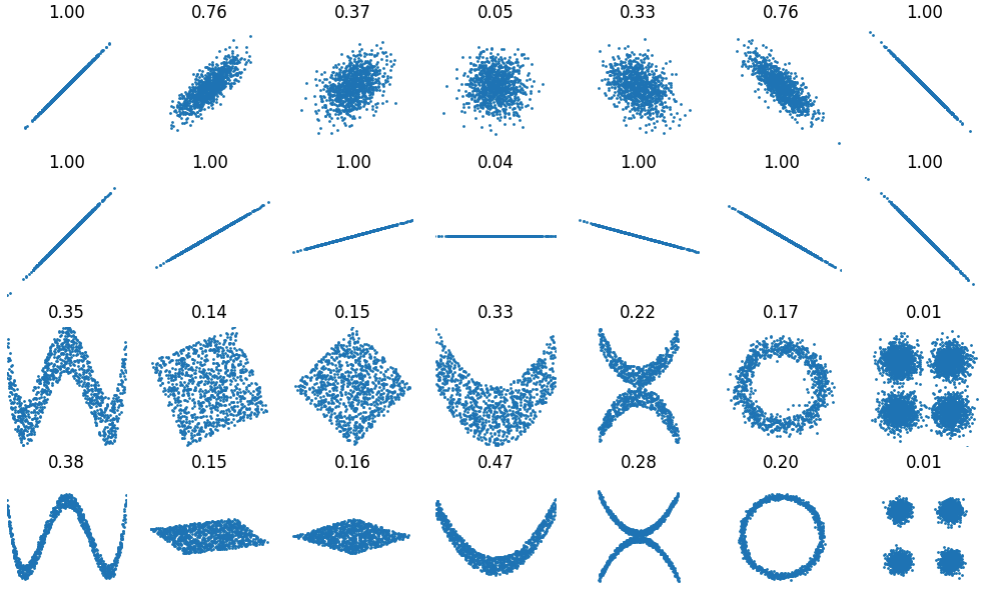

- **Distance correlation** : mesure toute dépendance (linéaire ou non), entre 0 et 1, 0 = indépendance
- **MIC** (Maximal Information Coefficient) : détecte relations non linéaires complexes, équitable

SCREE PLOT

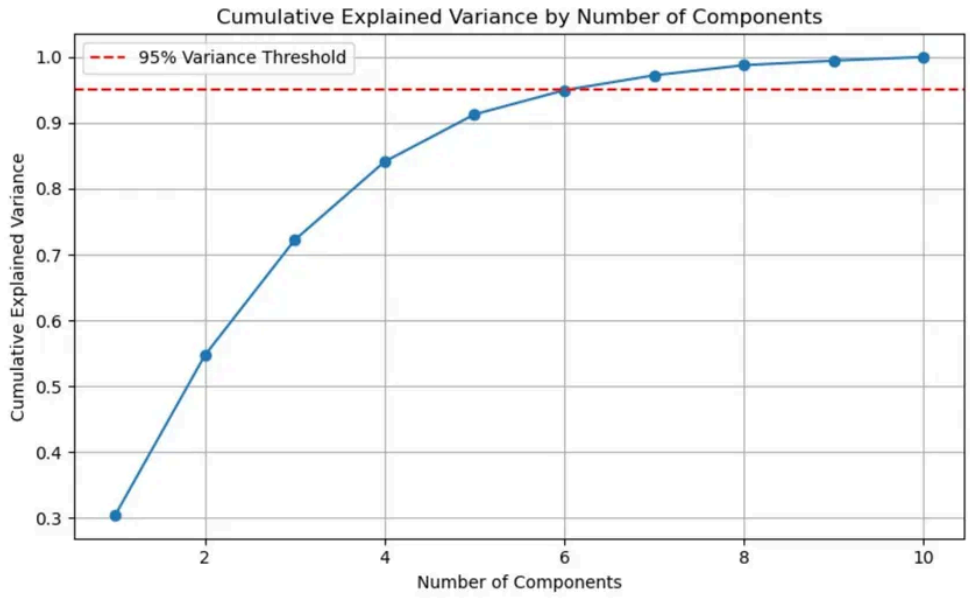

- **Principe** : trouver les axes qui expliquent le mieux la **variabilité** des données.
- **Objectif** : Capturer la variance globale, réduire le bruit, prétraiter les données
- **Quand l'utiliser** :
  - Pour des relations **linéaires** supposées entre variables
  - Quand la **vitesse** et l'**interprétabilité** sont critiques
  - En **prétraitement** avant t-SNE ou UMAP pour réduire la dimension et le bruit

- Pour une **intégration dans un pipeline ML** (transformations inversibles)

PCA : LE BIPLOT ET L'ÉCRAN DE VARIANCE

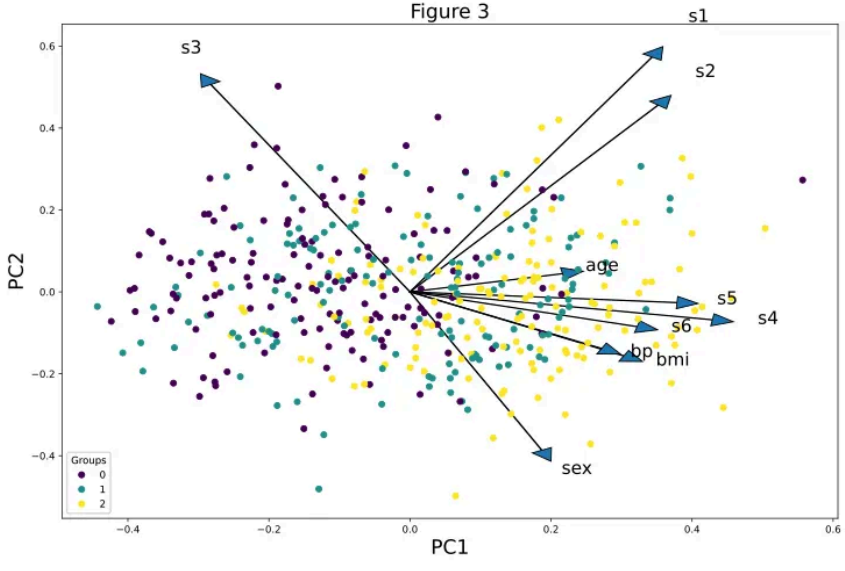

- Les **Biplots** sont utilisés pendant une PCA, ils permettent de projeter les données sur de nouvelles coordonnées (des 2 premières composants en abssisse et ordonée) pour découvrir de potentielles relations entre les données

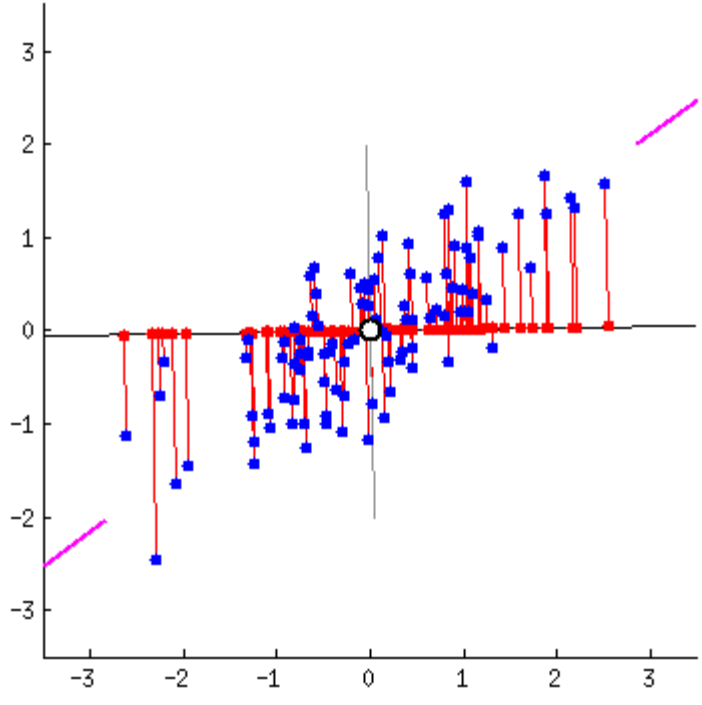
3
2
1
0
-1
-2
-3
-3
-2
-1
0
1
2
3

INTERPRÉTER CORRECTEMENT LES CORRÉLATIONS (LIMITES, CAUSALITÉ)

EXEMPLES

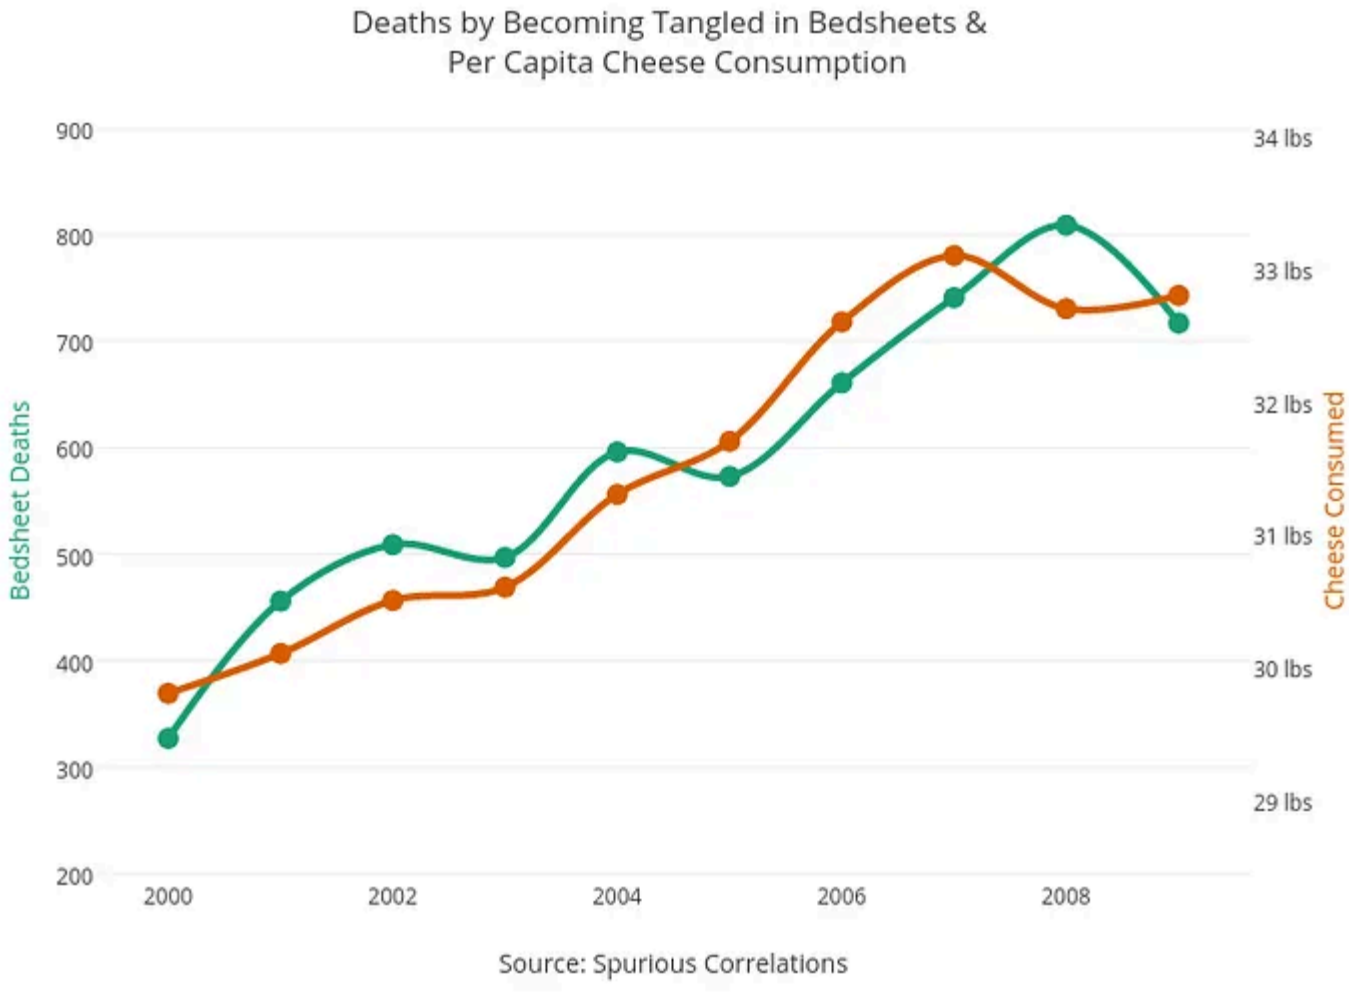
Deaths by Becoming Tangled in Bedsheets &
Per Capita Cheese Consumption
Bedsheet Deaths
900
800
700
600
500
400
300
200
Cheese Consumed
34 lbs
33 lbs
32 lbs
31 lbs
30 lbs
29 lbs
2000
2002
2004
2006
2008
Source: Spurious Correlations

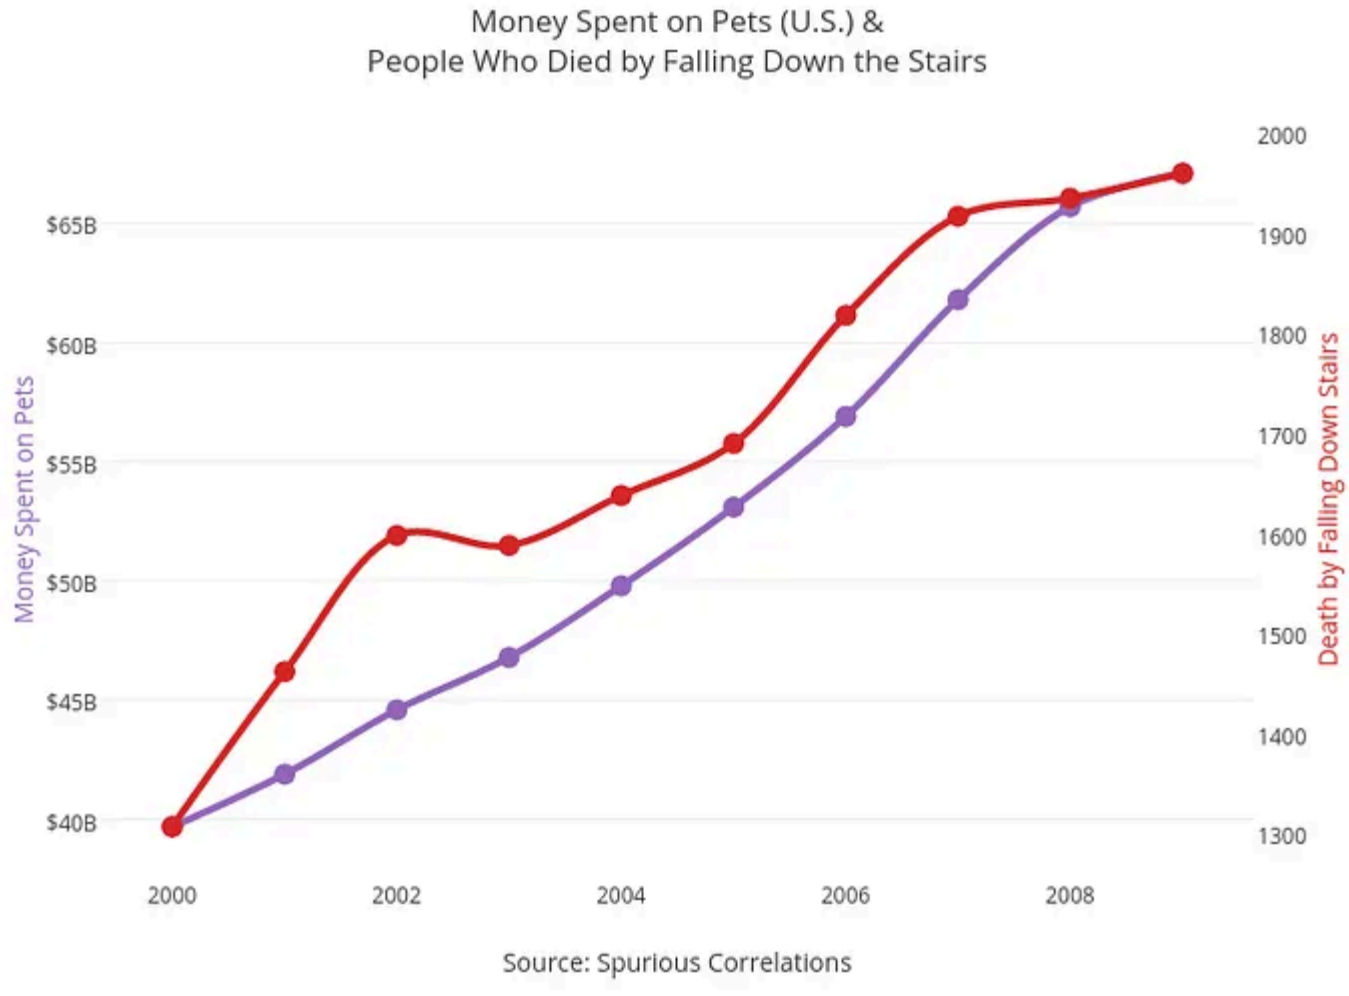
Money Spent on Pets (U.S.) &
People Who Died by Falling Down the Stairs
Money Spent on Pets
$65B
$60B
$55B
$50B
$45B
$40B
Death by Falling Down Stairs
2000
1900
1800
1700
1600
1500
1400
1300
2000
2002
2004
2006
2008
Source: Spurious Correlations

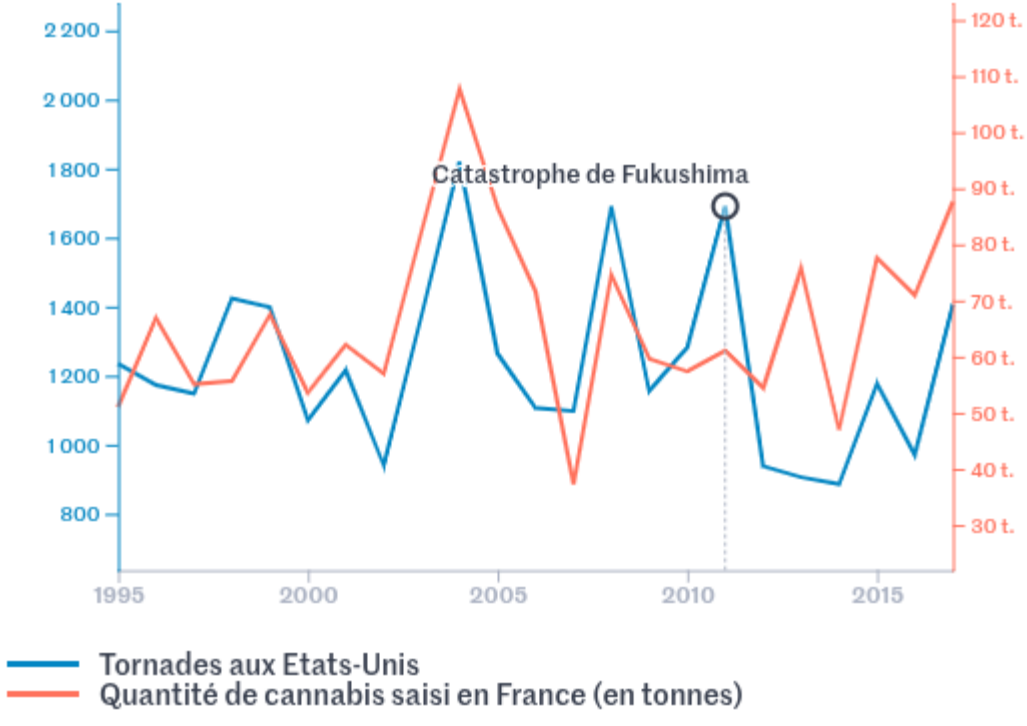
2 200
2 000
1 800
1 600
1 400
1 200
1 000
800
120 t.
110 t.
100 t.
90 t.
80 t.
70 t.
60 t.
50 t.
40 t.
30 t.
Catastrophe de Fukushima
1995
2000
2005
2010
2015
Tornades aux Etats-Unis
Quantité de cannabis saisi en France (en tonnes)

DÉFINITIONS

DÉFINITIONS

- **Corrélation**:
  - association statistique entre deux variables, où leurs variations tendent à se produire ensemble. Elle indique simplement qu'il existe une relation observable, mais **ne prouve pas** qu'une variable cause l'autre.

DÉFINITIONS

- **Corrélation**:
  - association statistique entre deux variables, où leurs variations tendent à se produire ensemble. Elle indique simplement qu'il existe une relation observable, mais **ne prouve pas** qu'une variable cause l'autre.
- **Causalité**:
  - affirme qu'une variable (la cause) **produit directement un changement dans une autre variable** (l'effet)

LA CORRÉLATION N'IMPLIQUE PAS LA CAUSALITÉ

- **Causes possibles** : causalité inverse, variable cachée, coïncidence
- **Exemple** : ventes de glaces et noyades (variable cachée : chaleur)
- **Comment établir la causalité ?** : expériences contrôlées, séries temporelles, mécanisme explicatif

CORRÉLATION PARTIELLE

- Mesure la relation entre deux variables en contrôlant l'effet d'une ou plusieurs variables tierces.
- **Calcul** : régresser chaque variable sur la variable de confusion, puis corréler les résidus.

```
from pingouin import partial_corr
import pandas as pd

# Exemple : corrélation entre X et Y, ajustée pour Z
result = pg.partial_corr(data=df, x=x,  y=x,  covar=z)


print(result.estimate)  # coefficient de corrélation partielle
```

DÉTECTION DE LA MULTICOLINÉARITÉ

- **VIF (Variance Inflation Factor)** : mesure combien la variance d'un coefficient est gonflée à cause des corrélations avec les autres variables.
  - VIF = 1 → aucune corrélation
  - 1 < VIF ≤ 5 → corrélation modérée (souvent acceptable)
  - VIF > 5 → multicolinéarité notable
  - VIF > 10 → multicolinéarité sévère (à corriger impérativement)
- **Que faire si VIF élevé ?**
  1. Supprimer l'une des variables corrélées.
  2. Combiner les variables (ex. BMI = poids / taille^2).
  3. Utiliser une réduction de dimension (PCA) ou une régularisation (Ridge, Lasso).

```python
from statsmodels.stats.outliers_influence import variance_inflation_factor

# X = DataFrame des variables explicatives
vif_data = pd.DataFrame()
vif_data["feature"] = X.columns
vif_data["VIF"] = [variance_inflation_factor(X.values, i) for i in
range(X.shape[1])]
print(vif_data)
```