DÉTECTION DES ANOMALIES

OBJECTIFS D'APPRENTISSAGE

- Détecter et caractériser les outliers avec différentes méthodes
- Valider la qualité des données de manière systématique
- Comparer les résultats avant et après nettoyage

TYPES D'ANOMALIES

Type	Description	Exemple
Ponctuelle	Valeur individuelle atypique	Transaction de 50k€ sur un compte habituel à 500€
Contextuelle	Anormale dans un contexte donné	Température de 35°C en hiver
Collective	Groupe d’observations formant un pattern anormal	Une absence d'activité cardiaque entre deux pulsations, ou absence continue sur une longue période

MÉTHODES DE DÉTECTION DE MACHINE LEARNING

ISOLATION FOREST

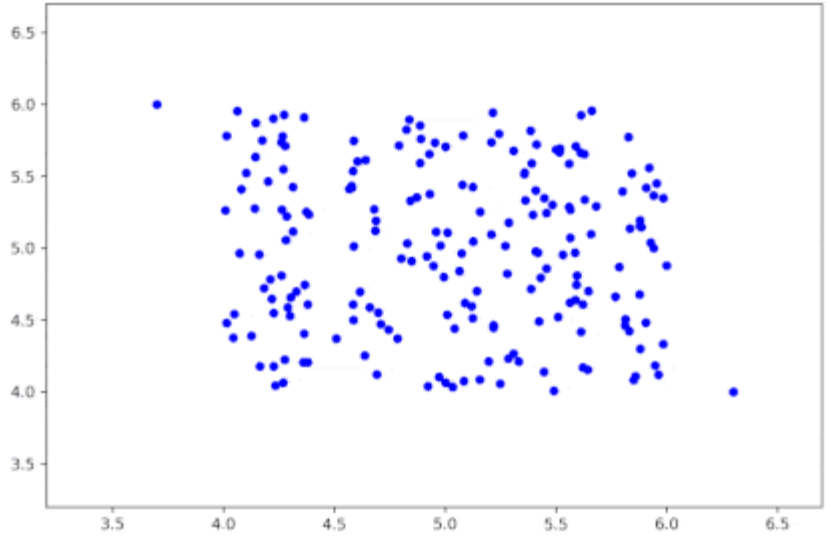

- Algorithme **non supervisé** et **stochastique**,
- Isole les anomalies avec moins de divisions
- Performant en haute dimension

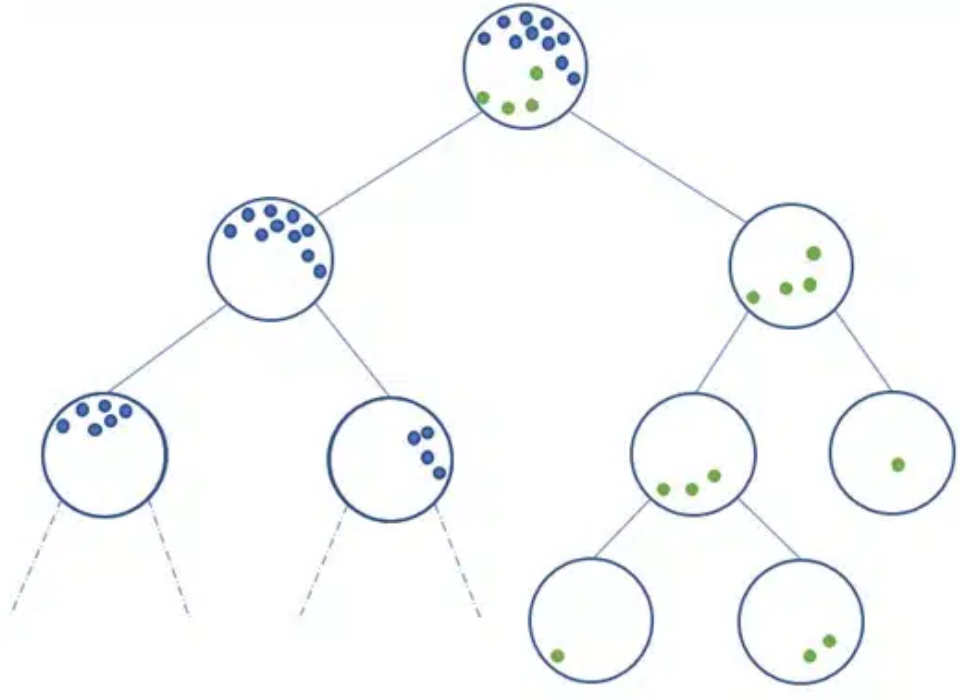

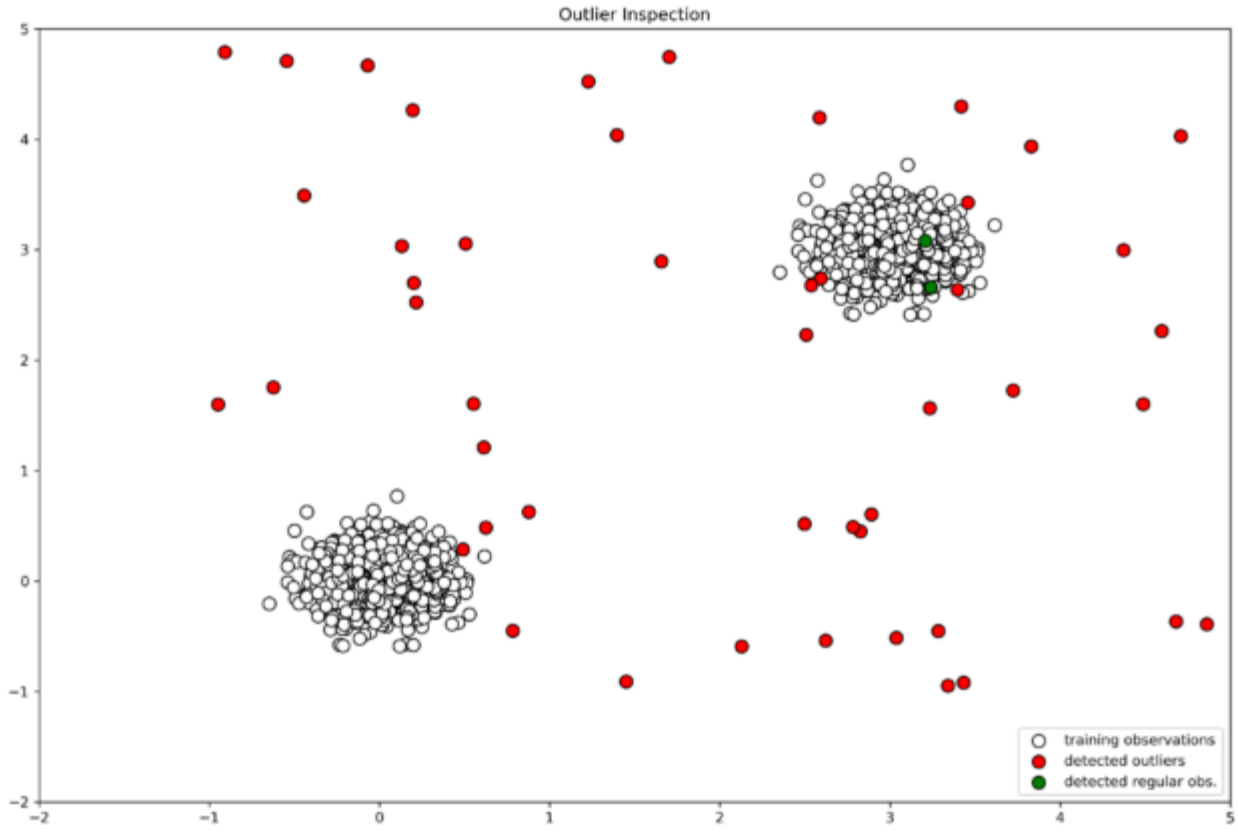


```
from sklearn.ensemble import IsolationForest
iso_forest = IsolationForest(contamination=0.1)
outliers = iso_forest.fit_predict(df'col')
```

LOCAL OUTLIER FACTOR (LOF)

Le Local Outlier Factor (LOF) est une méthode non supervisée qui identifie les anomalies en se basant sur la densité locale. Plutôt que de regarder une seule valeur (comme le z-score), LOF examine le voisinage d'un point.

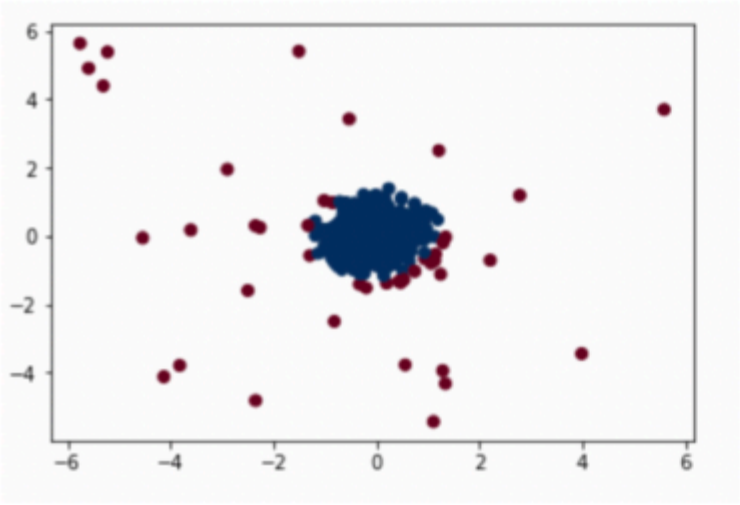

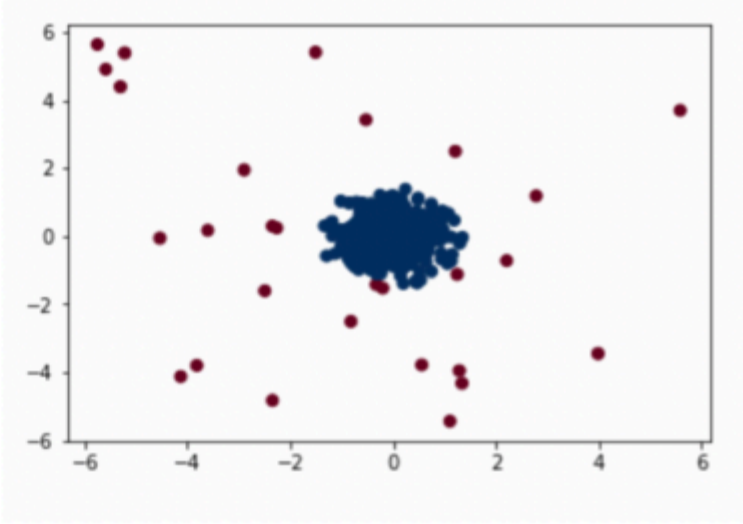


```
from sklearn.neighbors import LocalOutlierFactor
lof = LocalOutlierFactor()
outliers = lof.fit_predict(df'col1', 'col2')
```

APPLICATIONS WITH NOISE)

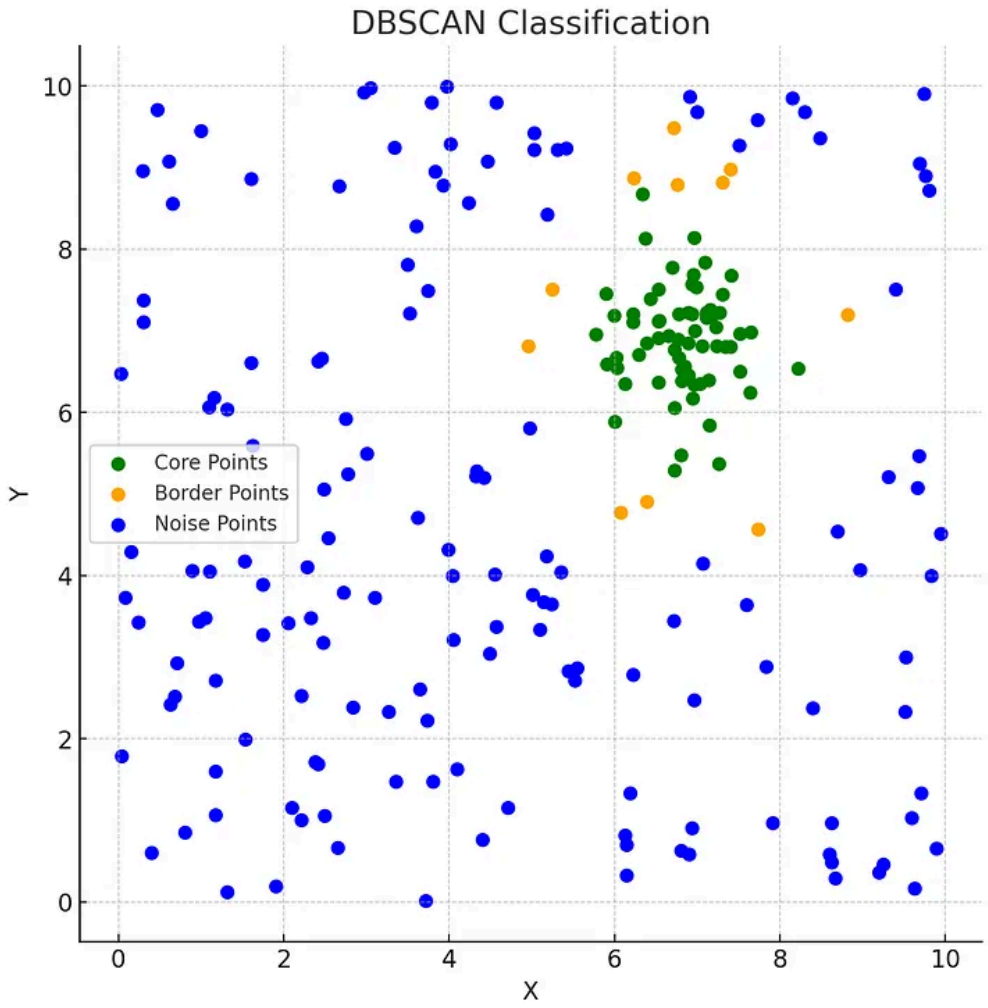

- **Principe** : les points proches forment des grappes (clusters). Les points isolés sont des anomalies. Il se base sur 2 paramètres clés: - **eps** : rayon autour d'un

point pour chercher des voisins. - **min_samples** : nombre minimum de voisins pour former une zone dense.

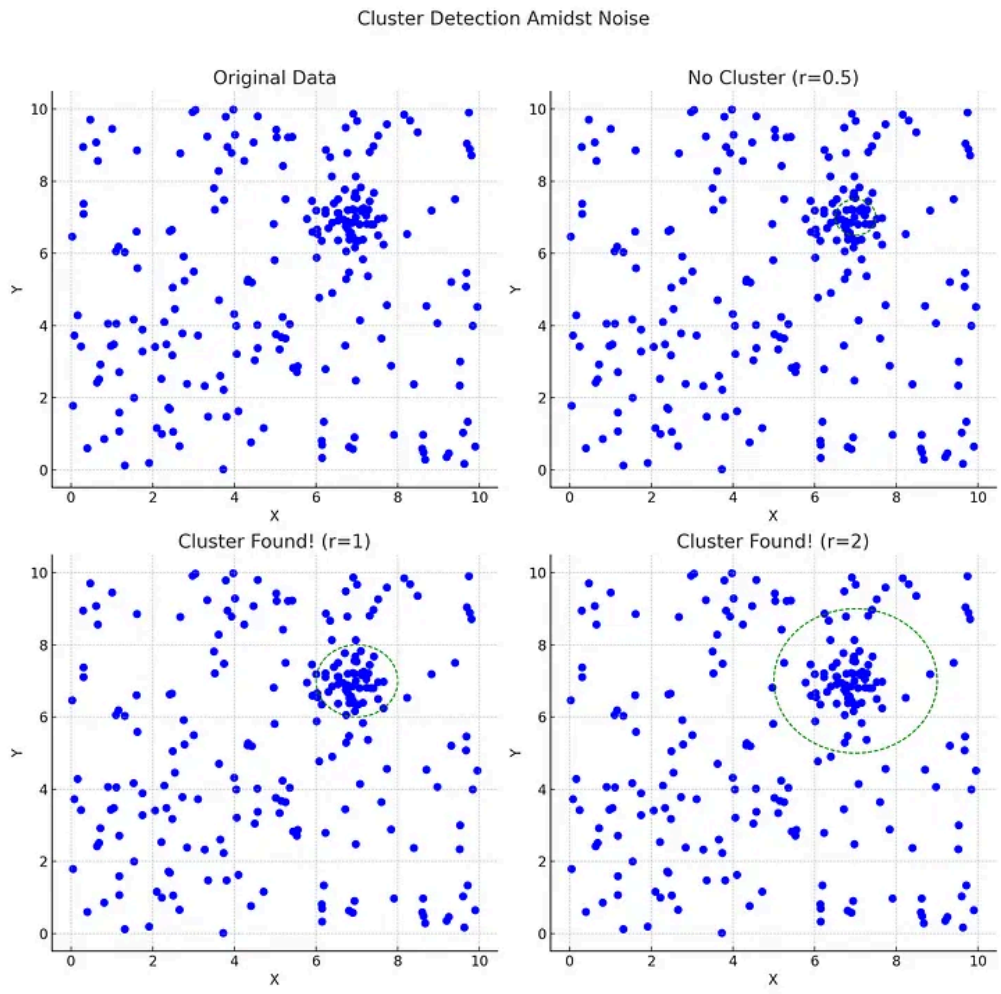


```
from sklearn.cluster import DBSCAN
dbscan = DBSCAN(eps=0.5, min_samples=5)
labels = dbscan.fit_predict(df'GrLivArea', 'SalePrice')
# labels = -1 pour les anomalies
```

VALIDER LA QUALITÉ DES DONNÉES DE MANIÈRE SYSTÉMATIQUE

STRATÉGIES DE TRAITEMENT DES OUTLIERS

- **Suppression** : si anomalie due à une erreur de saisie (documenter)
- **Winsorisation** : remplacer par les bornes supérieures/inférieures (ex. percentiles 1% et 99%/ 5% et 95%)
- **Transformation** : log, box-cox...
- **Imputation** : si valeur manquante, imputer par médiane, mode ou KNN
- **Conservation** : si l'outlier est un événement légitime (ex. fraude), le garder