EDA, VISUALISATION & FEATURE ENGINEERING

FONDAMENTAUX DE L'EDA ET STATISTIQUES DESCRIPTIVES

OBJECTIFS D'APPRENTISSAGE

- Comprendre les enjeux et la méthodologie systématique d'une EDA
- Maîtriser les statistiques descriptives univariées sur données tabulaires
- Distinguer statistiques classiques et robustes
- Identifier et documenter les problèmes de qualité des données

FRAMEWORK EDA MODERNE

INTRODUCTION GÉNÉRALE

L'**Analyse exploratoire des données (EDA)** est une approche fondamentale en science des données visant à **comprendre les caractéristiques principales d'un ensemble de données** avant toute modélisation formelle.

INTRODUCTION GÉNÉRALE

L'**Analyse exploratoire des données (EDA)** est une approche fondamentale en science des données visant à **comprendre les caractéristiques principales d'un ensemble de données** avant toute modélisation formelle.

1. **Data Understanding** — Comprendre la structure

INTRODUCTION GÉNÉRALE

L'**Analyse exploratoire des données (EDA)** est une approche fondamentale en science des données visant à **comprendre les caractéristiques principales d'un ensemble de données** avant toute modélisation formelle.

1. **Data Understanding** — Comprendre la structure
2. **Quality Assessment** — Évaluer la qualité

INTRODUCTION GÉNÉRALE

L'**Analyse exploratoire des données (EDA)** est une approche fondamentale en science des données visant à **comprendre les caractéristiques principales d'un ensemble de données** avant toute modélisation formelle.

1. **Data Understanding** — Comprendre la structure
2. **Quality Assessment** — Évaluer la qualité
3. **Pattern Discovery** — Découvrir les patterns

INTRODUCTION GÉNÉRALE

L'**Analyse exploratoire des données (EDA)** est une approche fondamentale en science des données visant à **comprendre les caractéristiques principales d'un ensemble de données** avant toute modélisation formelle.

1. **Data Understanding** — Comprendre la structure
2. **Quality Assessment** — Évaluer la qualité
3. **Pattern Discovery** — Découvrir les patterns
4. **Hypothesis Generation** — Formuler des hypothèses

COMPRÉHENSION DES DONNÉES

L'EDA permet une exploration initiale des caractéristiques principales du jeu de données, de sa structure et de son contenu.

- **Analyse univariée** : Utilisation d'histogrammes, boîtes à moustaches (box plots) ou diagrammes de densité pour comprendre la distribution des variables individuelles.
- **Analyse bivariée** : Nuages de points, matrices de corrélation ou tableaux croisés pour explorer les relations entre deux variables.
- **Analyse multivariée** : Matrices de dispersion, cartes de chaleur ou analyse en composantes principales (PCA) pour étudier simultanément plusieurs variables.

ÉVALUATION DE LA QUALITÉ DES DONNÉES

Une étape clé de l'EDA est la détection des problèmes de qualité :

- **Valeurs manquantes** : Identification via des rapports de qualité ou des visualisations (ex. : heatmap de présence).
- **Valeurs aberrantes** : Détectées par des méthodes comme l'intervalle interquartile (IQR) ou les scores z.
- **Incohérences ou erreurs** : Révélées par des anomalies dans les distributions ou des valeurs hors norme.
- **Fuite de caractéristique cible** : Évaluation de la corrélation entre variables et la cible pour éviter le surapprentissage.

COMPRÉHENSION DE LA DISTRIBUTION DES DONNÉES

- **Variables numériques** : tendance centrale (moyenne, médiane), dispersion (écart-type, variance, étendue), forme (symétrie, bimodalité)
- **Visualisations** : histogramme, boîte à moustaches (boxplot), courbe de densité (KDE), diagramme en violon
- **Variables catégorielles** : fréquences, effectifs, diagrammes en barres
- **Questions clés** : distribution normale ? asymétrique ? multimodale ? catégories rares ?

DÉCOUVERTE DE PATTERNS

Les visualisations jouent un rôle central dans la découverte de patterns :

- **Tendances temporelles** : Graphiques de séries chronologiques pour identifier des cycles ou des saisons.
- **Clusters ou groupes** : Nuages de points ou cartes de chaleur pour repérer des groupes naturels dans les données.
- **Relations non linéaires** : Visualisations interactives permettent d'observer des dépendances complexes.

GÉNÉRATION D'HYPOTHÈSES

L'EDA est une phase **exploratoire** et **hypothèse-générative**. Elle permet de formuler des questions comme :

- « Y a-t-il une corrélation entre le volume de vente et la région ? »
- « Les retards de livraison sont-ils plus fréquents en période de pointe ? »
- « Certaines variables sont-elles fortement corrélées à la cible ? »

Ces hypothèses sont ensuite testées par des méthodes **confirmatoires** (CDA), comme les tests statistiques ou les modèles prédictifs.

VOCABULAIRE DE L'EDA

MAÎTRISER LES STATISTIQUES DESCRIPTIVES UNIVARIÉES

LES TYPES DE VARIABLES – QUANTITATIVES

STATISTIQUES QUANTITATIVES

Pour une variable **quantitative** (ex. : heures de télévision par jour), les indicateurs clés

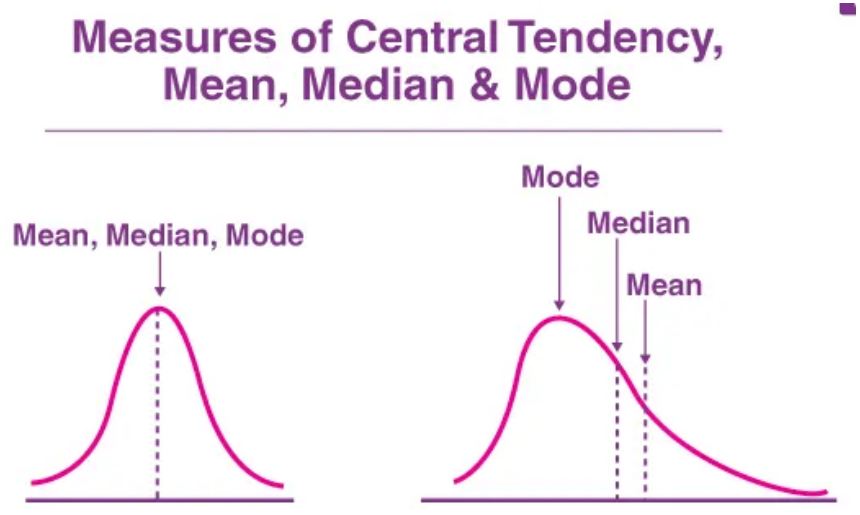

sont :

- **Tendance centrale** : moyenne (mean), médiane (median), mode.
- **Dispersion** : étendue, écart-type, écart interquartile, variance.
- **Forme de la distribution** : asymétrie (skewness), aplatissement (kurtosis).
- **Représentations graphiques** : histogramme, boîte à moustaches (boxplot), densité estimée, fonction de répartition cumulée.

LES TYPES DE VARIABLES – QUALITATIVES

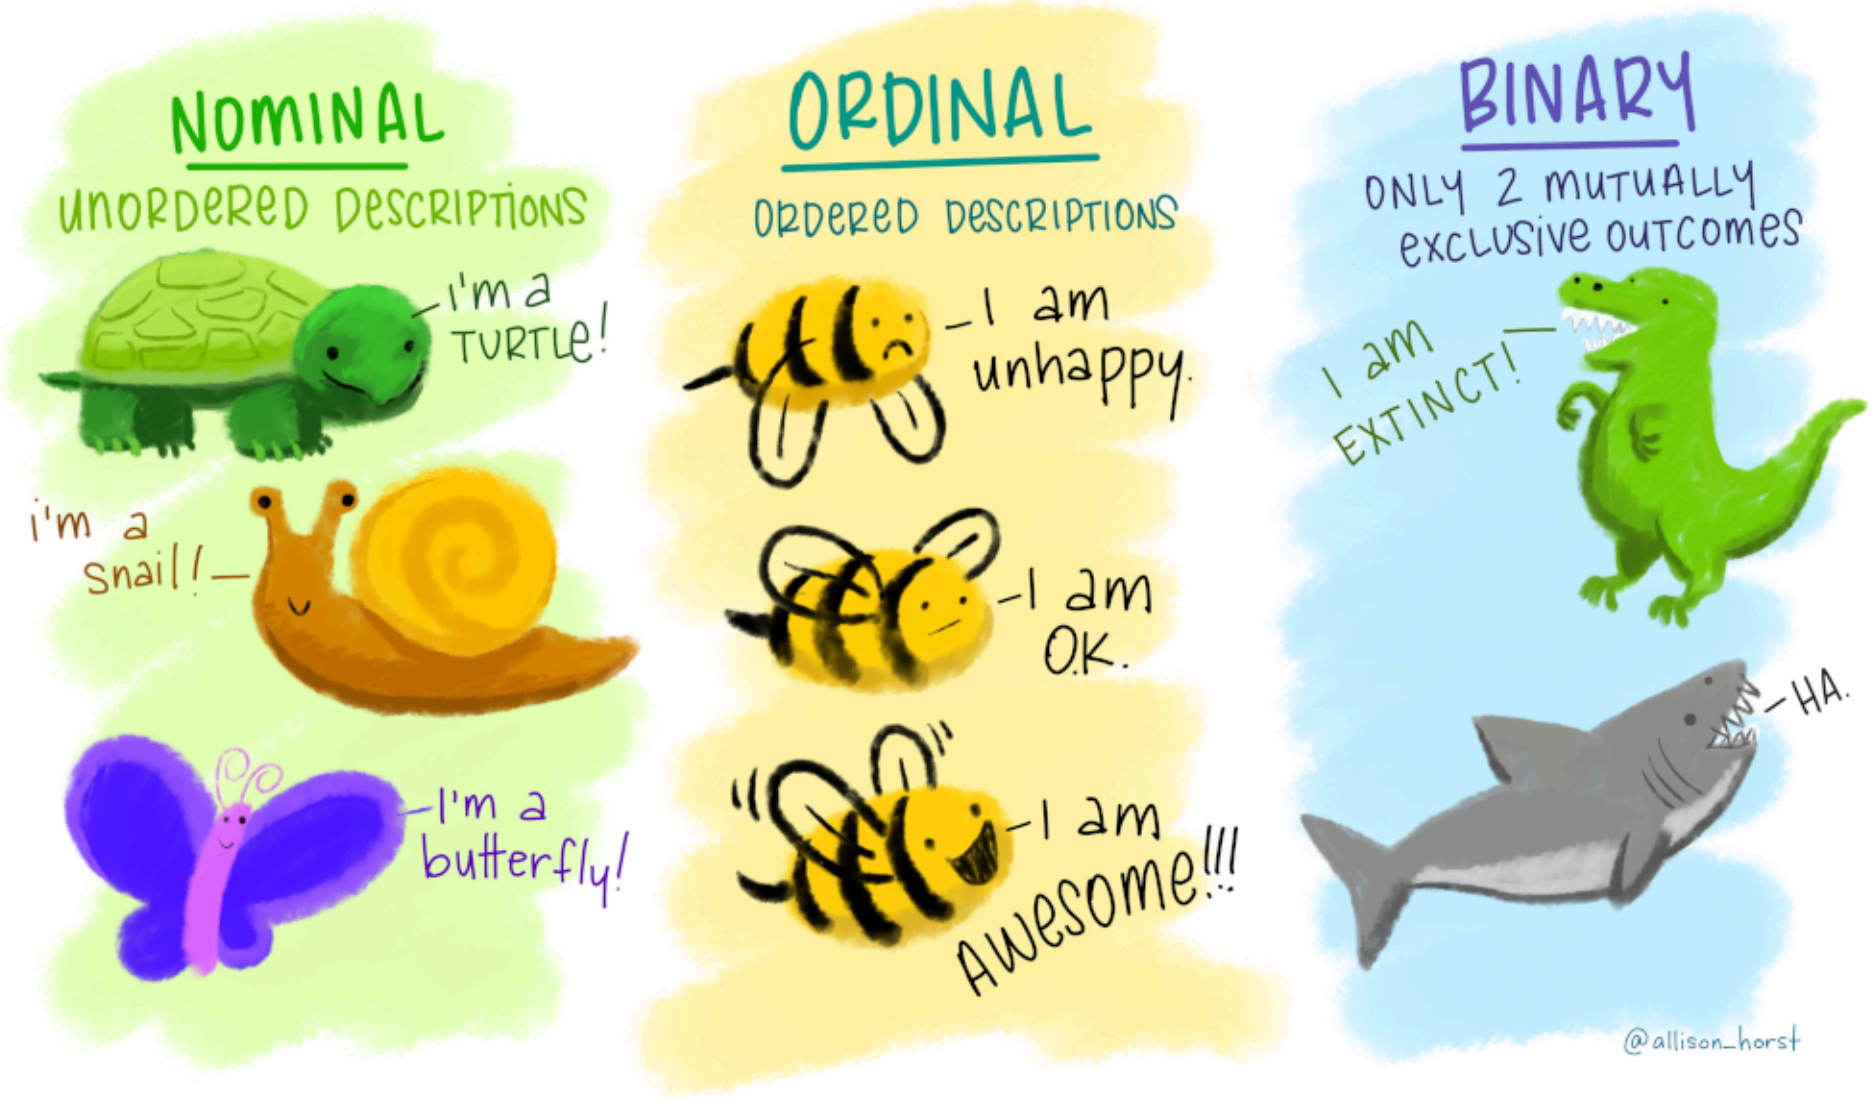

STATISTIQUES QUALITATIVES

Pour une variable qualitative (ex. : couleur des yeux), on utilise :

- **Fréquences** : effectifs et fréquences (absolues et cumulées).
- **Mode** : modalité la plus fréquente.
- **Graphiques** : diagramme à barres, diagramme circulaire (camenbert).

STATISTIQUES ROBUSTES VS CLASSIQUES

Deux approches principales coexistent : les **statistiques classiques** (ou traditionnelles) et les **statistiques robustes**, chacune adaptée à différents types de données et objectifs.

Mesure	Classique	Robuste
Centralité	Moyenne	Médiane
Dispersion	Écart-type	MAD, IQR
Détection	Z-score	Modified Z-score

DEEP DIVE: COMMENT CALCULER UN ÉCART-TYPE

5. Écart-type

La racine carré de la variance
$\sqrt{8} \approx 2{,}83$

Moyenne des carrés des écarts
(16 + 4 + 0 + 4 + 16) = 40
40 / 5 = 8

- évite que les écarts positifs et négatifs s'annulent (-4 + 4 = 0)
- donner plus de poids aux valeurs très éloignées.

1. moyenne

(8 + 10 + 12 + 14 + 16) / 5 =12

4. Calcul de la variance

3. écarts aux carré

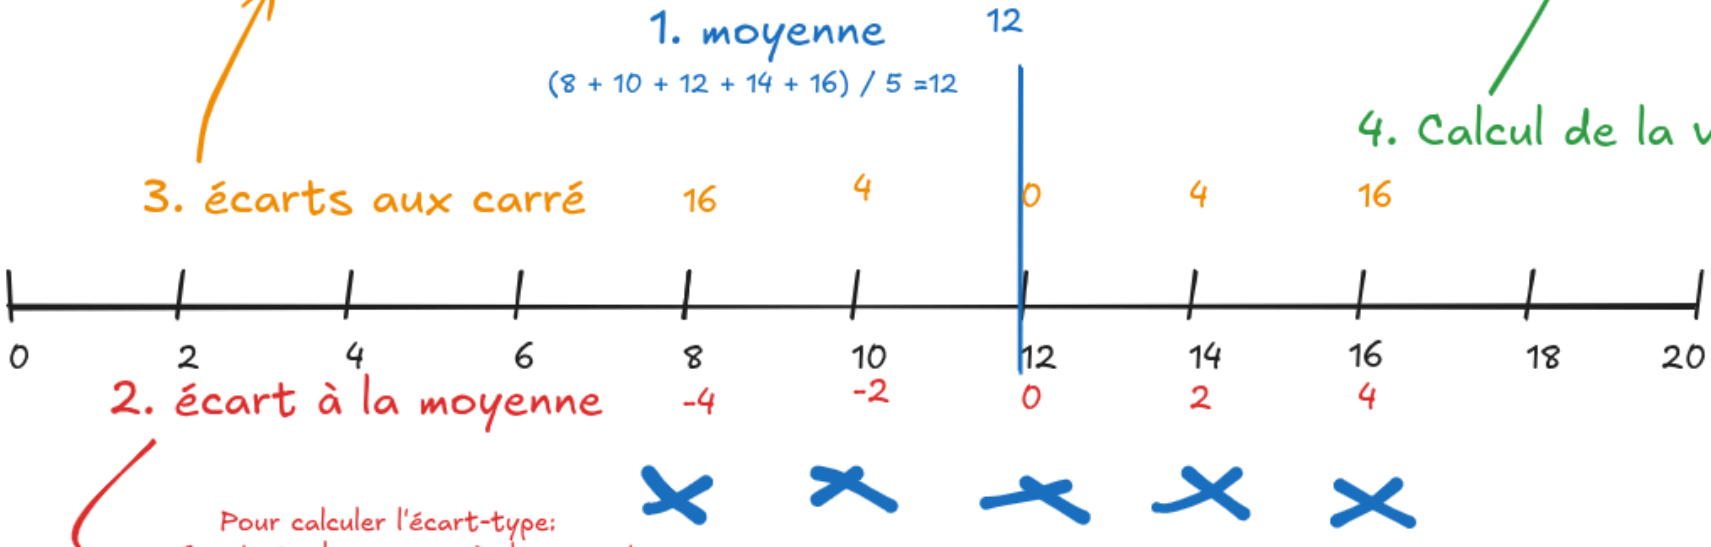

2. écart à la moyenne

Pour calculer l'écart-type:
Soustraire la moyenne à chaque note:

12 - 12 = 0
10 - 12 = -2
8 - 12 = -4
14 - 12 = 2
16 - 12 = 4

(8 - 12) / 2,8

= -1.41

$$\text{Z-score} = \frac{\text{valeur observée - moyenne}}{\text{Écart-Type}}$$

Z-SCORE : STANDARDISER POUR COMPARER

- Le **z-score**, ou **écart-type normalisé**, permet de comparer des valeurs provenant de séries différentes en les ramenant à une échelle commune, exprimée en nombre d'écarts-types par rapport à la moyenne.

$$\text{z-score} = \frac{\text{valeur observée} - \text{moyenne de la série}}{\text{écart-type de la série}}$$

- **Interprétation** :
  - z = 0 → note égale à la moyenne de sa série
  - z = 1 → 1 écart-type au-dessus de la moyenne
  - z = –1 → 1 écart-type en dessous

Z-SCORE : EXEMPLE CONCRET

- **Élève A** : 14/20 dans une classe où la moyenne est 12 et l'écart-type 2 →

$$z = \frac{14 - 12}{2} = 1$$

- **Élève B** : 13/20 dans une classe où la moyenne est 11 et l'écart-type 1,5 →

$$z = \frac{13 - 11}{1,5} \approx 1,33$$

- Bien que la note brute de B soit inférieure, son **z-score est plus élevé** : il se situe plus loin au-dessus de sa moyenne de classe.

Z-SCORE : LA LIMITE

- La **limite du z-score classique** est qu'il utilise la **moyenne** et l'**écart-type** – très sensibles aux valeurs extrêmes.
- **Exemple simple** :
  - Dans une classe, les notes sont : 8, 10, 12, 14, 16.
  - La moyenne est 12, l'écart-type ≈ 2,8.
  - Si on ajoute une note de 40 (erreur de saisie)
    - la moyenne monte à 16,7, l'écart-type devient 11,2.
    - Le z-score de la note 40 est (40-16,7)/11,2 = 2,08

DEEP DIVE: COMMENT CALCULER UN ÉCART-TYPE – ERREUR

5. Écart-type Très élevé à cause du 30 et du 0 (valeurs extrêmes).

- évite que les écarts positifs et négatifs s'annulent (-4 + 4 = 0)
- donner plus de poids aux valeurs très éloignées.

La racine carré de la variance
√71,81 ≈ 8.47

Moyenne des carrés des écarts
(165,3 + 23,6 + 8,2 + 0,7 + 1,3 + 293,7) = 502,7
502.7 /7 = 71,81

1. Moyenne

(0 + 8 + 10 + 12 + 14 + 16 + 30) / 7
= 12.86

12.86

4. Calcul de la variance

3. écarts aux carré

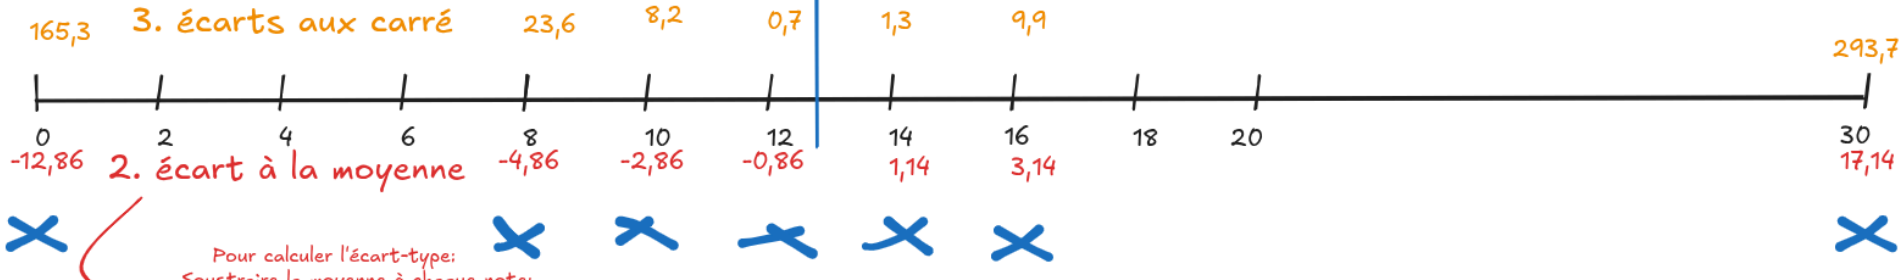

2. écart à la moyenne

Pour calculer l'écart-type:
Soustraire la moyenne à chaque note:

12 - 12,86 = -0,86
10 - 12,86 = -2,86
8 - 12,86 = -4,86
0 - 12,86 = -12,86
14 - 12,86 = 1,14
16 - 12,86 = 3,14
30 - 12,86 = 17,14

(30 - 12.86) / 8.47 = 2.023612751

(0 - 12.86) / 8.47 = -1.518299882

$$\text{Z-score} = \frac{\text{valeur observée - moyenne}}{\text{Écart-Type}}$$

Z-SCORE MODIFIÉ : SOLUTION

- **Solution** : utiliser la **médiane** (centre robuste) et le **MAD** (médiane des écarts absolus à la médiane). Le seuil habituel est de Z-score > 3,5 (≈ IQR x 1.5)

$$Z_{\text{modifié}} = 0{,}6745 \times \frac{(\text{valeur observée} - \text{médiane})}{\text{MAD}}$$

- **Pourquoi 0,6745 ?** Pour que, dans une distribution normale, le M soit comparable au z-score classique.
- **Même exemple avec médiane** :
  - Dans une classe, les notes sont : 8, 10, 12, 14, 16, 40.
  - La médiane est 12. Le MAD est la médiane des écarts absolus à la médiane : 0,2,2,4,4,28 → médiane = 3.
  - Le z-score modifié de 40 est : 0,6745 × (40-12)/3 ≈ 6,3 → bien au-delà du seuil, détection claire.

COMMENT CALCULER UN ÉCART-TYPE ROBUSTE

Écart-type Robuste

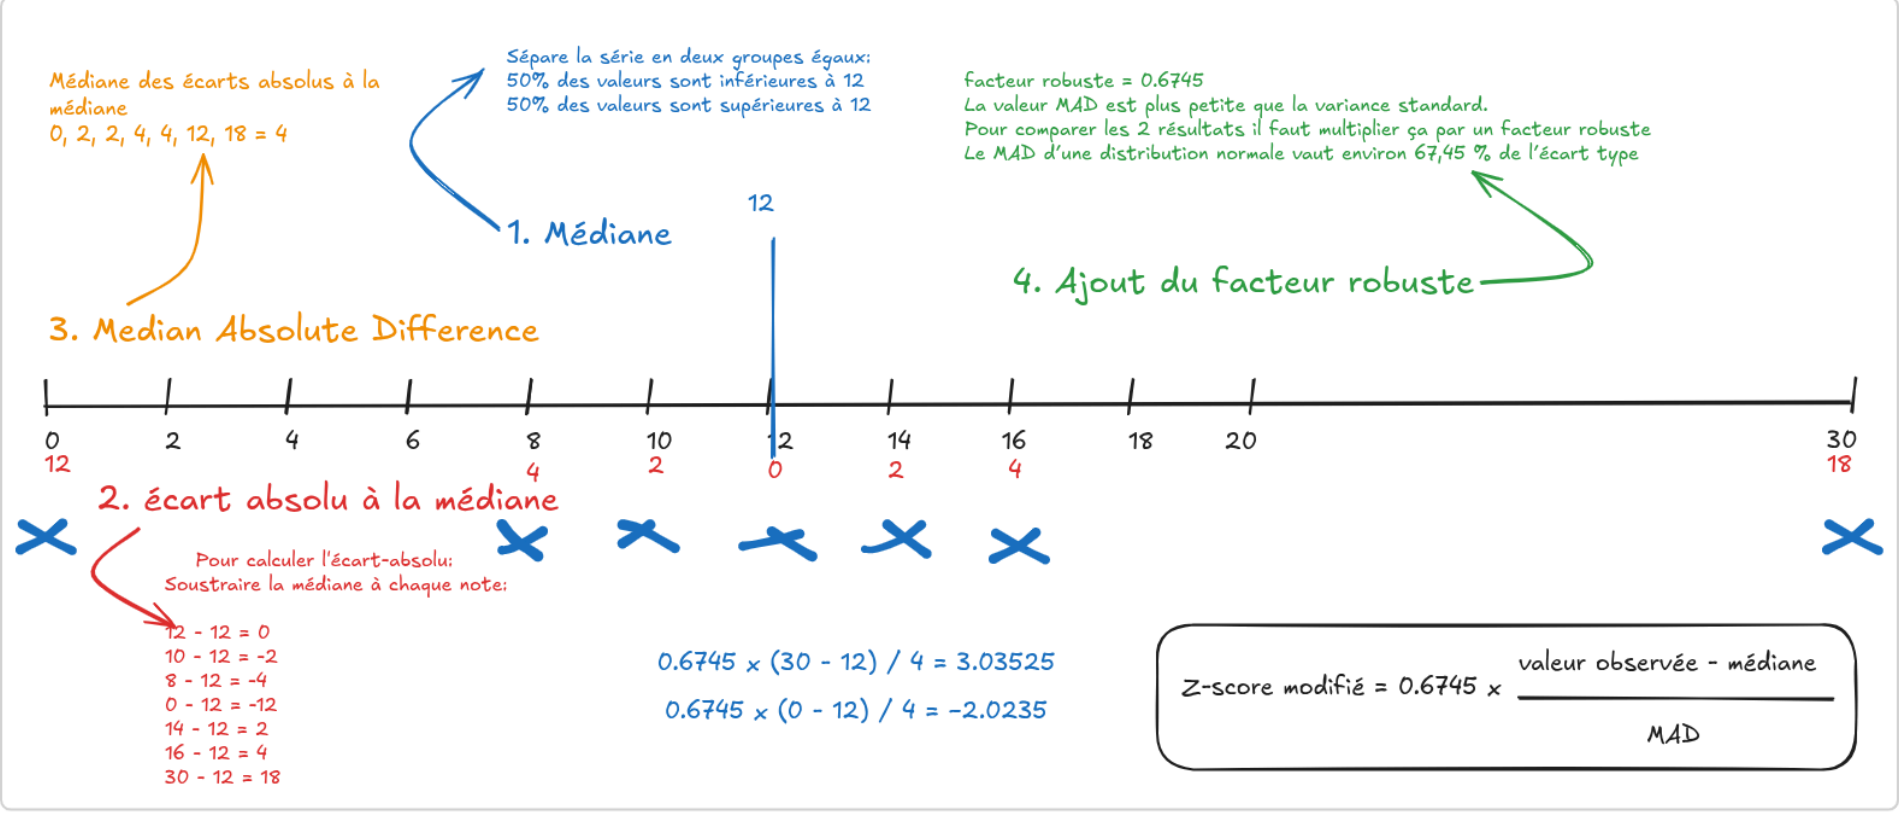

DÉTECTION PRÉLIMINAIRE D'ANOMALIES

La détection préliminaire d'anomalies repose sur des méthodes statistiques simples et efficaces, notamment la **règle de l'IQR** et le **z-score modifié**, toutes deux robustes aux valeurs aberrantes.

- **Règle IQR :**
  - Bornes : [Q1 - 1.5×IQR, Q3 + 1.5×IQR]
  - Robuste aux données asymétriques
  - Utilisée dans les boxplots
- **Z-score modifié :**

$$Z_{\text{modifié}} = 0{,}6745 \times \frac{(\text{valeur observée} - \text{médiane})}{\text{MAD}}$$

  - Seuil : |Modified Z| > 3.5
  - Fonctionne sur petits échantillons

FORME DES DISTRIBUTIONS

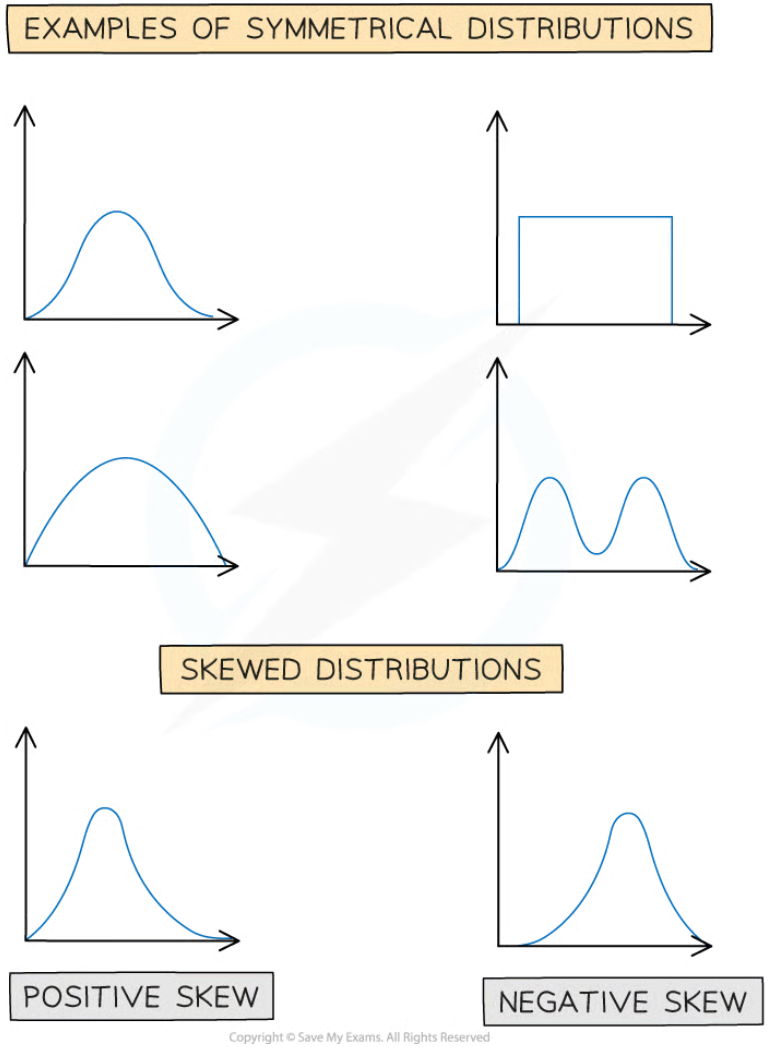

Copyright © Save My Exams. All Rights Reserved

ASYMÉTRIE (SKEWNESS)

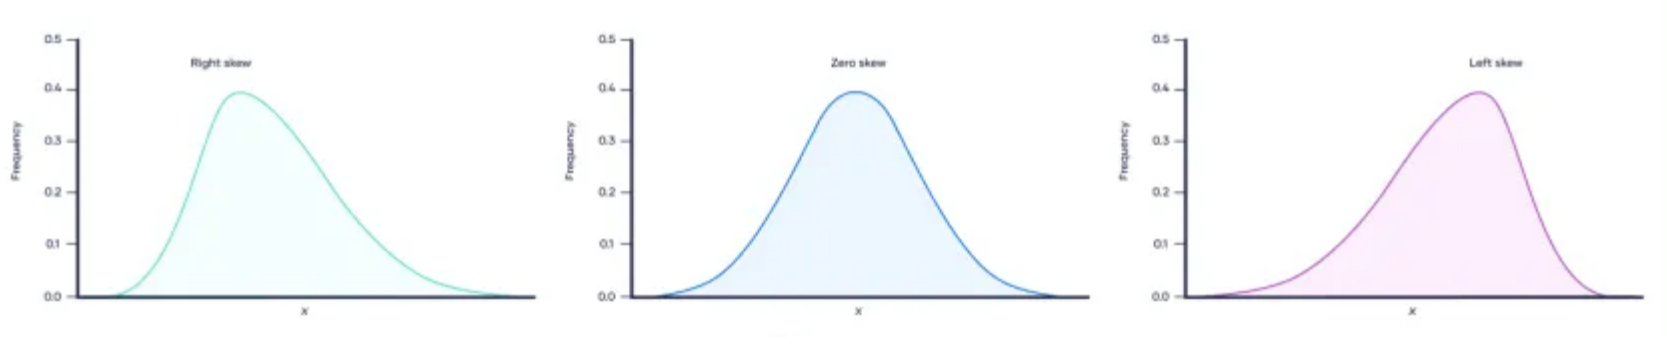

- L'**asymétrie** ou **skewness** mesure l'asymétrie d'une distribution par rapport à son centre.
  - **Positive (à droite)** : valeurs faibles rares (moyenne > médiane)
  - **Négative (à gauche)** : valeurs élevées rares (moyenne < médiane)
  - **Nulle** : distribution symétrique (ex. loi normale)

APLATISSEMENT (KURTOSIS)

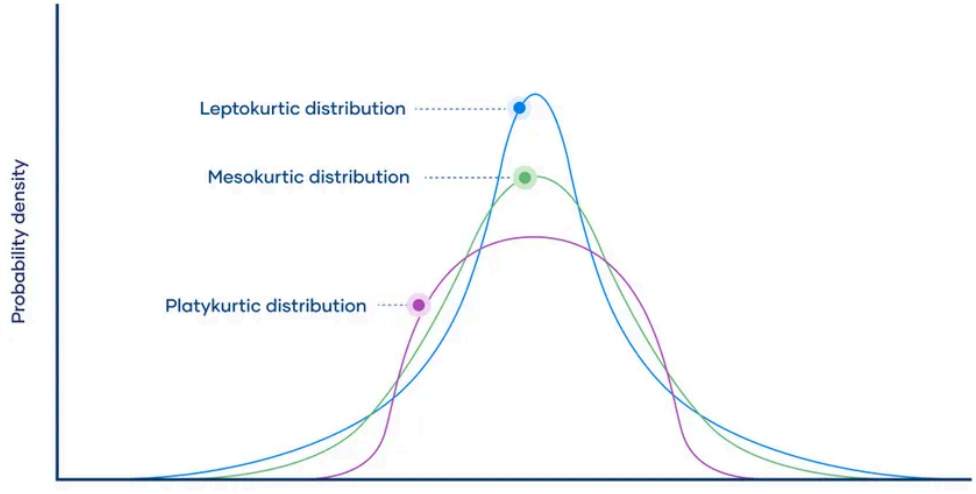

- L'**applatissement** mesure l'importance des queues/extrêmes d'une distribution par rapport à une loi normale.
  - **Leptokurtique (kurtosis > 0)** : queues épaisses, plus de valeurs extrêmes (risque de outliers)
  - **Mésokurtique (kurtosis ≈ 0)** : queues semblables à la normale
  - **Platykurtique (kurtosis < 0)** : queues fines, moins de valeurs extrêmes

ÉLÉMENTS CLÉS À DOCUMENTER

- **Objectif métier** : Problématique concrète
- **Hypothèses explicites** : Assertions testables
- **Variables clés** : Features prioritaires
- **Contraintes** : Limitations connues

BONNES PRATIQUES

Hypothèse	Variable(s) testée(s)	Méthode de vérification	Statut
Durée → Satisfaction	duration, satisfaction_score	Corrélation, boxplot par groupe	Validée
Type chambre → Note	room_type, rating	ANOVA, comparaison moyennes	En cours