Analyse exploratoire & feature engineering

Un parcours complet d'analyse du jeu Ames Housing, de l'exploration des données à l'optimisation des modèles de prédiction de prix immobiliers.

Contexte du projet

Jeu de données Ames Housing

Une base riche avec **79 variables** décrivant 1 460 maisons vendues à Ames, Iowa entre 2006 et 2010.

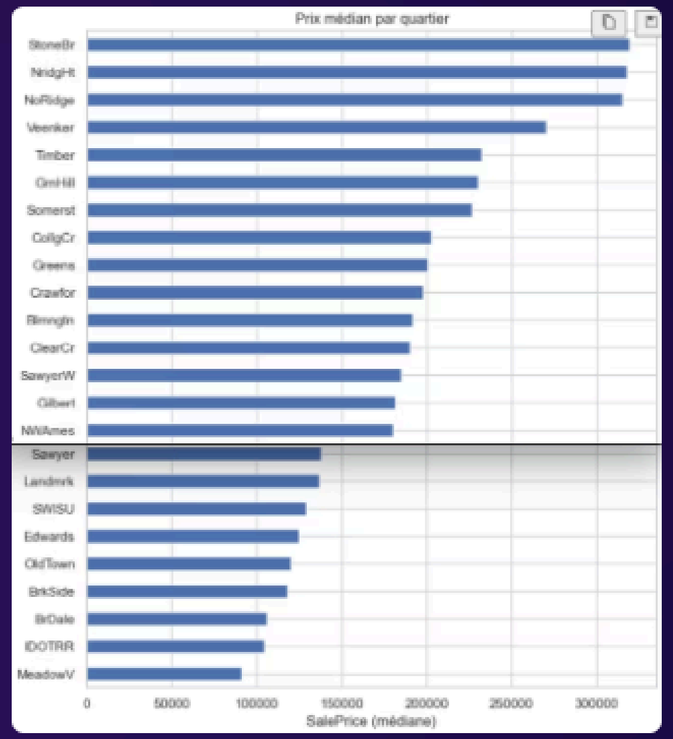

Distribution du prix de vente

Concentration

La majorité des ventes se concentrent entre **100 000$ et 200 000$**, visible sur l'histogramme et la KDE.

Asymétrie positive

Queue à droite marquée (*skew*) indiquant des valeurs élevées rares mais significatives.

Transformation log

Le **Q-Q plot** révèle une non-normalité. La transformation **log1p(SalePrice)** sera utilisée pour améliorer les modèles.

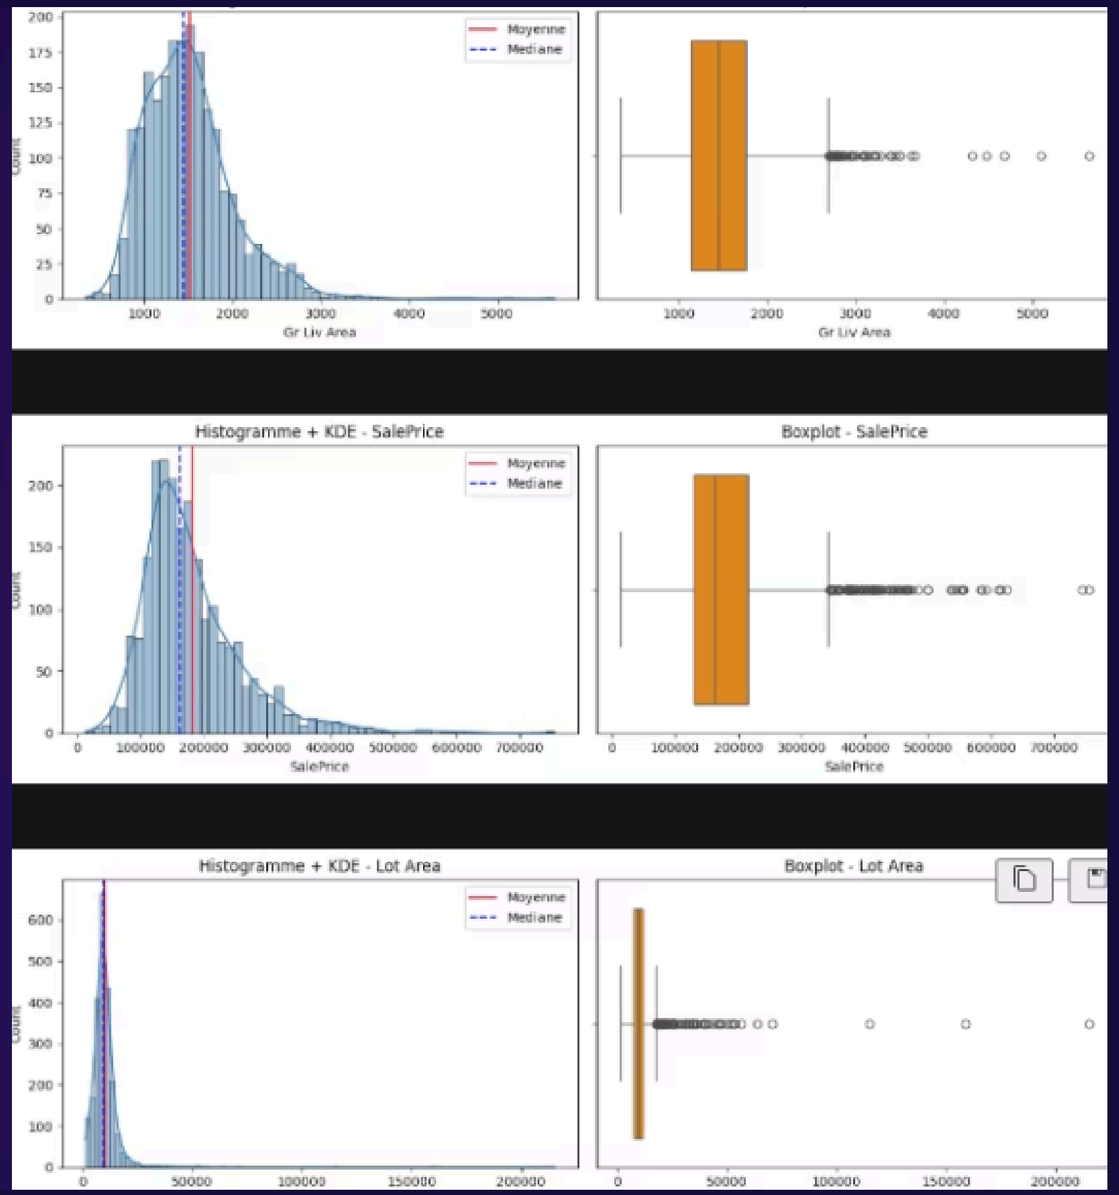

Prix et localisation par quartier

Écarts marqués

La variable **Neighborhood** révèle des écarts de niveau de prix significatifs selon la localisation.

Levier clé

La localisation est un facteur déterminant du prix. À compléter par des variables structurelles pour affiner l'analyse.

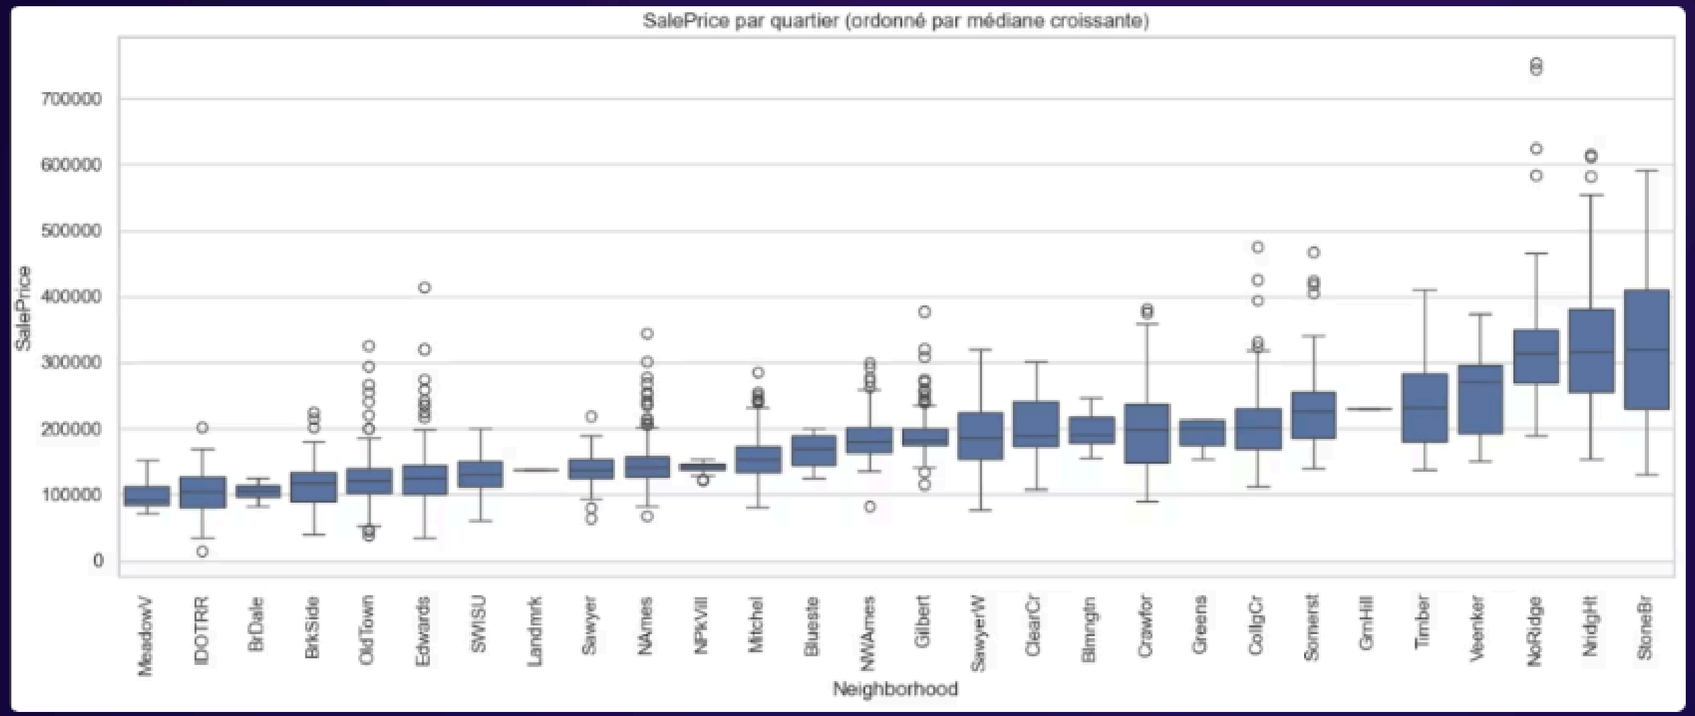

Notebook

Histogramme + KDE

Visualisation de la distribution avec concentration principale et queue à droite.

Boxplot

Identification des **outliers** hauts et mesure de la dispersion interquartile.

HeatMap

corrélations les plus fortes des neighborhood avec les

Variables catégorielles : effectifs

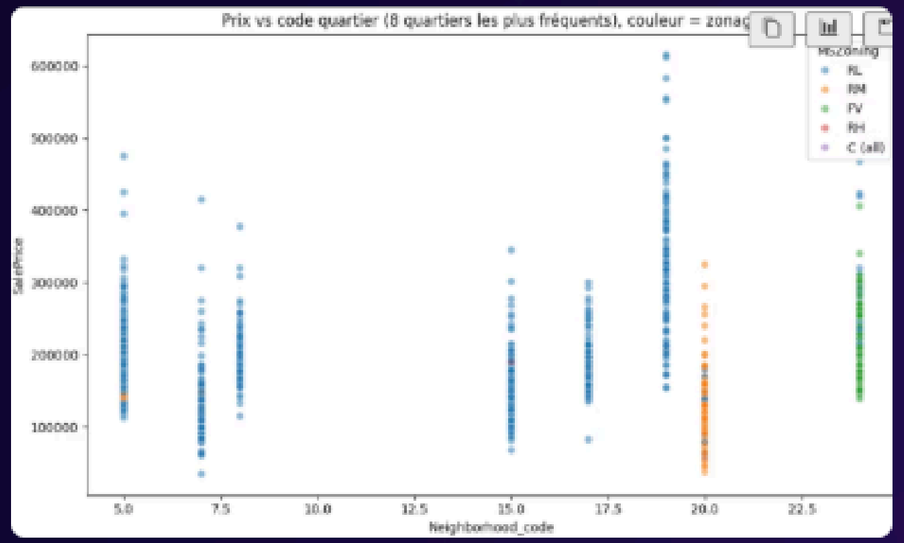

Neighborhood

Modalités **déséquilibrées** : NAmes, CollgCr et OldTown dominent.

MSZoning

RL (Residential Low density) représente la quasi-totalité.

Conditions

Condition1/2 : quasi tout **Norm** → faible variabilité. Condition2 quasi constante.

Amélioration des performances du modèle (RMSE)

53k

Localisation seule

35k

+ variables structurelles

33k

+ log + Ridge / FE

31.8k

+ features métier enrichies

Résultats

- E5bis (localisation seule) → **~53k**
- + variables structurelles (surface, qualité) → **~35k**
- + log + Ridge / FE → **~33k**
- + features métier enrichies → **~31.8k**

Insights clés

- Ajouter des variables réduit fortement l'erreur
- Les variables structurelles sont plus explicatives que la localisation seule
- La transformation **log1p(y)** améliore la stabilité du modèle
- Le feature engineering apporte un gain marginal mais décisif

Merci de votre attention